BASES DE DATOS AVANZADAS · DATA WAREHOUSE

DWMusicBrainz

Capa Gold y dashboard analítico

Documento técnico de defensa: modelo dimensional, calidad de datos, modelo semántico, justificación estadística y visual del dashboard, y guion de presentación ante la junta directiva.

1.728.603
lanzamientos únicos en el modelo

15.000.000
pistas analizadas

690.454
artistas con producción registrada

2012
año en que el digital superó al CD

Autor: Juan Sebastián Rincón Farelo · Generado el 17/10/2026 desde PostgreSQL 16 (dw_musicbrainz)

CONTENIDO

Índice

Resumen ejecutivo . . . 3
Contexto, arquitectura y alcance . . . 3
Diseño dimensional (metodología Kimball) . . . 4
Tabla de hechos gold.fact_produccion_musical . . . 5
Dimensiones conformadas . . . 6
Hecho de distribución y dimensión de bandas . . . 7
Diseño físico y rendimiento . . . 7
Calidad de datos y hallazgos de auditoría . . . 7
Modelo semántico en Power BI . . . 8
Diseño del dashboard . . . 9
Justificación de cada gráfico . . . 10
Fundamentos estadísticos . . . 11
Trazabilidad de requisitos . . . 13
Limitaciones y trabajo futuro . . . 13
Preguntas probables del profesor . . . 13
Guion para la junta directiva . . . 14
Catálogo de medidas DAX . . . 16
Glosario . . . 17

SECCIÓN 1

Resumen ejecutivo

La capa **Gold** de DWMusicBrainz transforma el modelo relacional normalizado (3FN) de la capa Silver en un **modelo dimensional en estrella** según la metodología de Ralph Kimball, optimizado para preguntas analíticas sobre la producción musical registrada en MusicBrainz. Sobre ese modelo se construyó un **modelo semántico en Power BI** con medidas DAX y un **dashboard de dos páginas**: un resumen ejecutivo y un análisis detallado.

1.728.603 Lanzamientos únicos	**15.000.000** Pistas analizadas	**690.454** Artistas activos	**22,4 %** Cobertura ISRC
28,2 % Participación digital (histórica)	**4:08** Duración media por pista (m:ss)	**8,7** Pistas por lanzamiento	**965.241** Horas de audio catalogadas

Hallazgos principales

- **Transición de formato:** el formato digital superó al CD óptico en **2012** y en 2025 representa el **90,6 %** de los lanzamientos con fecha, frente al 6,4 % del CD.
- **Duración de las canciones:** entre 1950 y 2025 la duración media por año se correlaciona positivamente con el año (r de Pearson = 0,89); desde 2013, con el digital dominante, la tendencia se invierte (r = -0,57, -1,01 s por año).
- **Distribución:** la duración es unimodal con moda en **3:30–4:00** (14,2 % de las pistas), mediana en la misma banda y media de 4:08: asimetría positiva (cola larga a la derecha).
- **Volumen ≠ digitalización:** los países con más lanzamientos no son los más digitalizados; por ejemplo, South Korea tiene 41,7 % de lanzamientos digitales.
- **Gobierno del dato:** la auditoría de la capa Gold detectó y corrigió cuatro defectos (sección 8), entre ellos un conteo no aditivo que inflaba el KPI principal y un mapeo de idiomas incorrecto.

SECCIÓN 2

Contexto, arquitectura y alcance

El proyecto sigue una **arquitectura por capas (medallion)**: los volcados oficiales de MusicBrainz (archivos TSV dentro de `mbdump.tar.bz2`) se cargan con `COPY` en la capa **Silver** (tablas normalizadas en 3FN con auditoría en `meta.etl_audit`). La capa **Gold** desnormaliza esa información en un esquema en estrella orientado al negocio y con nombres en español.

Capa	Propósito	Modelo	Objetos principales
Raw	Archivos originales del volcado	TSV	mbdump/*
Silver	Datos limpios, tipados y auditados	Relacional 3FN	release, medium, track, recording, artist, area, language, isrc…
Gold	Consumo analítico (OLAP)	Estrella (Kimball)	2 hechos, 7 dimensiones, 4 vistas materializadas
Semántica	Medidas de negocio y visualización	Power BI (Import)	22 medidas DAX, 2 páginas de dashboard

Alcance de los datos

- La tabla `silver.track` se cargó con las **primeras 15.000.000 pistas** del volcado (carga controlada por espacio en disco). Por lo tanto, el análisis cubre los lanzamientos que tienen pistas dentro de ese subconjunto: **1.728.603** de 5.858.206 lanzamientos de Silver.
- El subconjunto **no es una muestra aleatoria**: corresponde al orden del archivo. Las conclusiones describen el catálogo cargado y no deben generalizarse sin esa salvedad.
- Base de datos PostgreSQL 16 con un tamaño actual de 16 GB.

SECCIÓN 3

Diseño dimensional (metodología Kimball)

El modelo se diseñó con los cuatro pasos de Kimball: (1) elegir el proceso de negocio, (2) declarar el grano, (3) identificar las dimensiones y (4) identificar los hechos.

Paso	Decisión	Justificación
1. Proceso	Producción musical (publicación de pistas en lanzamientos)	Es el evento medible que responde las preguntas de negocio RF01–RF08.
2. Grano	Un registro por día × artista × perfil de lanzamiento × país × formato × idioma	Grano atómico suficiente para todos los cortes del dashboard sin perder detalle temporal.
3. Dimensiones	fecha, artista, lanzamiento (perfil), geografía, formato, idioma	Son los ejes de análisis pedidos: tiempo, quién, qué tipo, dónde, soporte y lengua.
4. Hechos	11 métricas numéricas aditivas	Solo números que se pueden sumar en cualquier dimensión; los textos viven en las dimensiones.

Declaración del grano

«Un registro de `gold.fact_produccion_musical` representa la producción musical consolidada de un día para una combinación de artista, perfil de lanzamiento, país, formato e idioma.»

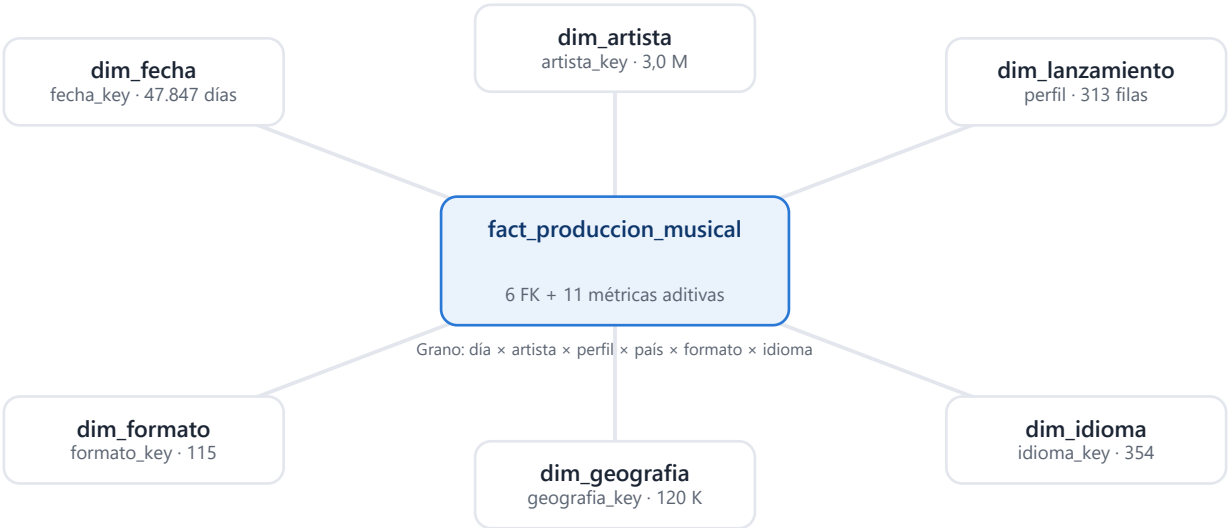


Figura 1. Esquema en estrella de la capa Gold (hecho principal y sus seis dimensiones conformadas).

Decisiones de diseño clave

- **Claves subrogadas enteras** (*_key) en lugar de las claves naturales de MusicBrainz: aíslan el DW de cambios en la fuente, hacen los joins más rápidos y permiten el patrón de fila desconocida.
- **Patrón Key 0 (fila desconocida):** cada dimensión tiene una fila con clave 0 (por ejemplo «Sin País Registrado», «Idioma No Especificado»). Todo valor faltante apunta a esa fila, por lo que el hecho nunca tiene claves huérfanas y los totales siempre cuadran.
- **dim_lanzamiento como dimensión de perfil:** en lugar de una fila por lanzamiento (5,8 M), guarda las combinaciones de estado, empaque y calidad (313 filas). Es una *junk dimension* que evita una dimensión gigante sin perder capacidad de análisis.
- **Hecho sin textos ni booleanos:** los indicadores (tiene ISRC, es pista larga, es video) se guardan como conteos aditivos, nunca como banderas, para que `SUM` funcione en cualquier nivel de agregación.

Matriz de bus (dimensiones conformadas por proceso)

Hecho	fecha	artista	lanzamiento	geografía	formato	idioma	rango duración
fact_produccion_musical (diario)	X	X	X	X	X	X	
fact_distribucion_duracion (anual)	X (año)			X	X	X	X

Ambos hechos comparten las mismas dimensiones conformadas, por lo que un filtro por año, país, formato o idioma afecta a los dos de forma coherente (*drill-across*).

SECCIÓN 4

Tabla de hechos gold.fact_produccion_musical

Contiene **2.967.681 filas**, con 6 claves foráneas y 11 métricas. Todas las métricas son **aditivas**: se pueden sumar en cualquier combinación de dimensiones y el resultado es correcto.

Métrica	Cálculo en el ETL	Significado
lanzamientos_total	1 en la fila de la primera pista de cada lanzamiento	Lanzamientos únicos (álbumes, sencillos, EP…)
soportes_total	1 en la fila de la primera pista de cada soporte	Discos, casetes o medios digitales únicos
pistas_total	COUNT(pista)	Pistas (tracks) publicadas
grabaciones_unicas_total	1 en la primera aparición de cada grabación	Grabaciones distintas
duracion_total_ms / _segundos / _minutos	SUM(duración de la pista)	Tiempo total de audio
pistas_con_isrc_total	SUM(1 si la grabación tiene ISRC)	Pistas con código internacional ISRC
pistas_largas_total	SUM(1 si dura más de 5 min)	Pistas largas
pistas_video_total	SUM(1 si es video)	Pistas de video
pistas_completas_total	SUM(1 si tiene duración)	Denominador para promedios de duración

> **Por qué las métricas de conteo son aditivas (regla de asignación)**
>
> Un `COUNT(DISTINCT lanzamiento)` calculado por fila **no es aditivo**: si un álbum tiene pistas de dos artistas o se editó en dos formatos, aparece en dos filas y al sumarlas se cuenta dos veces. Por eso el ETL asigna cada lanzamiento, soporte y grabación a **una sola fila**, la de su primera pista (función de ventana `ROW_NUMBER() OVER (PARTITION BY lanzamiento ORDER BY soporte, pista)`). Así, `SUM(lanzamientos_total)` = 1.728.603 = número exacto de lanzamientos distintos en Silver, comprobado por el control de calidad `CONCILIACION_LANZAMIENTOS_UNICOS`.

Consecuencia de la regla de asignación

Si un lanzamiento mezcla artistas o formatos, se atribuye al artista y al formato de su primera pista. Es la convención estándar para mantener la aditividad; la alternativa (repartir fracciones) complica la interpretación sin cambiar las tendencias. Las métricas de pistas y duración no se ven afectadas porque cada pista ocupa exactamente una fila.

Regla de fecha

La fecha es la del primer evento de publicación del lanzamiento (país conocido primero, luego país desconocido). Si el lanzamiento no tiene fecha, va a la clave 0 «Sin fecha» (140.150 lanzamientos). No se imputa con otros datos, porque eso generaba anacronismos (sección 8).

SECCIÓN 5

Dimensiones conformadas

Dimensión	Filas	Atributos principales	Uso en el dashboard
dim_fecha	47.847	fecha_completa, anio, trimestre, mes, nombre_mes, decada, siglo, es_fin_de_semana	Rango de años, décadas, series de tiempo
dim_artista	3.015.713	nombre_artista, tipo_artista, genero, nombre_pais, anio_inicio, anio_fin	Tipo de artista, Top 20 artistas
dim_lanzamiento	313	estado_lanzamiento, tipo_empaque, calidad_datos (perfil)	Filtro por estado del lanzamiento
dim_formato	115	nombre_formato, categoria_formato (Digital, Óptico, Vinilo, Magnético, Otros)	Mezcla de formatos, participación digital
dim_geografia	120.109	nombre_area, tipo_area, nombre_pais	Top países, dispersión por país
dim_idioma	354	nombre_idioma, codigo_iso (catálogo oficial ISO 639-3)	Top idiomas, filtro por idioma
dim_rango_duracion	22	etiqueta_rango, limite_inferior_seg, limite_superior_seg	Histograma de duración

- **SCD Tipo 1:** las dimensiones se actualizan sobrescribiendo atributos (`ON CONFLICT … DO UPDATE`). Es suficiente porque el análisis no requiere historial de cambios de atributos (por ejemplo, el nombre de un idioma).
- **dim_fecha** es un calendario continuo 1900–2030 más la fila desconocida. Por esa fila (fecha nula), Power BI no permite marcarla como tabla de fechas; las medidas de tendencia trabajan por año con SELECTEDVALUE.
- **dim_geografia** incluye países, regiones, ciudades y subdivisiones. El atributo `tipo_area` permite filtrar solo países; la categoría «No Aplica» agrupa áreas que no son países (por ejemplo, regiones o «Worldwide»).

SECCIÓN 6

Hecho de distribución y dimensión de bandas

El hecho principal agrega la duración por día y dimensiones, por lo que no conserva la duración individual de cada pista. Para analizar la **distribución** (histograma) se creó un segundo proceso dimensional:

- **gold.dim_rango_duracion** (*band dimension*): 20 bandas de 30 s entre 0:00 y 10:00, una banda abierta «10:00+» y la clave 0 «Sin duración».
- **gold.fact_distribucion_duracion** (584.923 filas): grano **año × formato × idioma × país × banda**, con `pistas_total` y `duracion_total_ms`.
- **Conciliación:** suma 15.000.000 pistas, exactamente igual al hecho principal (control `CONCILIACION_PISTAS_DISTRIBUCION`).
- **Ancho de banda de 30 s:** con más de 14 millones de observaciones, la regla de Sturges ($k \approx 1 + \log_2(n) \approx 25$ clases) sugiere un número de clases similar a las 21 elegidas; 30 s es además una unidad fácil de leer para negocio.
- **Grano anual:** se eligió año en lugar de día para mantener el hecho pequeño. No incluye artista, por lo que el filtro de tipo de artista no afecta al histograma (limitación documentada).

SECCIÓN 7

Diseño físico y rendimiento

- **Particionamiento por rango** de `fecha_key` en 15 particiones (fecha desconocida, pre-1970, décadas 1970–2010, años 2020–2025, 2026+ y una partición por defecto). PostgreSQL descarta particiones que no cumplen el filtro (*partition pruning*), lo que acelera las consultas por período.
- **Índices B-Tree** en cada clave foránea del hecho para acelerar los joins con las dimensiones.
- **4 vistas materializadas** pre-agregadas (tendencias anuales, analítica de artistas, evolución de formatos y distribución geográfica) para consultas SQL rápidas fuera de Power BI.
- **Modo Import en Power BI:** el modelo comprime ~6,7 M de filas en memoria (motor VertiPaq), así que los visuales responden sin consultar PostgreSQL en cada interacción.

SECCIÓN 8

Calidad de datos y hallazgos de auditoría

Antes de construir el dashboard se auditó la capa Gold con consultas DAX y SQL. Se encontraron y corrigieron cuatro defectos. Documentarlos es parte del gobierno del dato: muestra que las cifras del dashboard fueron verificadas.

#	Defecto encontrado	Impacto	Corrección
1	lanzamientos_total y soportes_total se calculaban con COUNT(DISTINCT) por fila y luego se sumaban.	El KPI principal contaba lanzamientos repetidos (3,2 M en lugar de los valores únicos).	Regla de asignación a la primera pista con ROW_NUMBER(); control de conciliación contra Silver.
2	Si un lanzamiento no tenía fecha, se usaba el año de inicio del artista o la fecha de edición del registro.	Anacronismos: CD o digital fechados en 1920 o 1950.	Sin fecha real → clave 0 «Sin fecha». Los gráficos de tendencia muestran 1950–2025.
3	dim_idioma usaba un CASE con IDs escritos a mano que no coincidían con MusicBrainz.	Etiquetas falsas: «Húngaro» era japonés; «Japonés» era «varios idiomas».	Se cargó el catálogo oficial silver.language (7.846 idiomas) y se resuelve con JOIN.

#	Defecto encontrado	Impacto	Corrección
4	Los lanzamientos con idioma nulo se renombraban como «Otro Idioma (0)».	La fila desconocida perdía su significado.	La clave 0 se restablece como «Idioma No Especificado».

Controles automáticos (meta.data_quality_log)

Control	Resultado
Integridad referencial hecho → dim_fecha	0 huérfanos
Integridad referencial hecho → dim_artista	0 huérfanos
Integridad referencial hecho → dim_lanzamiento	0 huérfanos
Integridad referencial hecho → dim_geografia	0 huérfanos
Integridad referencial hecho → dim_formato	0 huérfanos
Integridad referencial hecho → dim_idioma	0 huérfanos
Conciliación lanzamientos únicos (Gold vs Silver)	1.728.603 = 1.728.603
Conciliación soportes únicos (Gold vs Silver)	1.882.045 = 1.882.045
Conciliación pistas (hecho principal vs distribución)	15.000.000 = 15.000.000

Datos especiales de MusicBrainz tratados en el dashboard

- Artistas especiales como `[unknown]`, `[anonymous]` o `[no artist]` no son artistas reales; se excluyen del Top 20 (filtro «no empieza con [»).
- El ranking de países usa solo `tipo_area = 'País'`, para no mezclar países con regiones.
- Las series de tiempo terminan en 2025: 2026 está incompleto y el catálogo contiene fechas futuras anunciadas.

SECCIÓN 9

Modelo semántico en Power BI

Relaciones

- Todas las relaciones son **1:N con filtro en una sola dirección** (de la dimensión al hecho). Es la configuración recomendada para un esquema en estrella: evita ambigüedades y resultados inesperados.
- Power BI había detectado dos caminos hacia dim_geografia (directo desde el hecho y a través de dim_artista.area_id). Se desactivó el camino por artista y se activó el directo: así «país» significa país del lanzamiento. El país de origen del artista sigue disponible como atributo en dim_artista.
- Se ocultaron claves técnicas y columnas numéricas del hecho, y se desactivó la suma automática de claves y años, para que el usuario solo use medidas explícitas.
- Se desactivó «Fecha/hora automática», que creaba tablas de calendario ocultas por cada columna de fecha.

Medidas DAX (tabla _Medidas)

Las medidas se agrupan en carpetas: Volumen, Duración, Calidad, Formatos, Tendencia y Distribución. El catálogo completo con su código está en el Anexo A. Tres decisiones técnicas importantes:

- **DIVIDE** en lugar de «/»: devuelve vacío cuando el denominador es cero en lugar de un error.

- **Promedio ponderado:** la duración promedio es SUM(segundos) / SUM(pistas con duración), no un promedio de promedios. Un promedio de promedios daría el mismo peso a un día con 1 pista que a uno con 10.000.
- **ALLSELECTED** en los porcentajes de participación: el denominador respeta los filtros que el usuario eligió, así que los porcentajes siempre suman 100 % dentro de la selección.

SECCIÓN 10

Diseño del dashboard

Principios aplicados

- **Regla 3-30-300:** en 3 segundos se entiende el propósito (título y KPIs), en 30 segundos los hallazgos (gráficos principales) y en 300 segundos se puede explorar el detalle (segmentadores, tabla y página de análisis).
- **Jerarquía visual (Stephen Few):** arriba los filtros, luego los KPIs, después la tendencia y al final el desglose. La lectura sigue el patrón en Z, de arriba a la izquierda hacia abajo a la derecha.
- **Relación datos-tinta (Edward Tufte):** sin efectos 3D, sin sombras y con cuadrícula tenue. En los rankings se muestra el valor sobre la barra y se elimina el eje numérico redundante.
- **Una pregunta por página:** el Resumen ejecutivo responde «¿cuánto y cómo cambió la industria?»; el Análisis detallado responde «¿qué la caracteriza por época, país, idioma y artista?».
- **Lienzo de 1280 × 720 px** con márgenes de 15 px y separación de 5 px, validado sin superposiciones.

Teoría del color

Elemento	Color	Razón
CD óptico	Azul #2A78D6	Formato dominante del período físico; color base del informe.
Digital / Streaming	Naranja #EB6834	Complementario del azul: máximo contraste para los dos protagonistas de la transición.
Vinilo	Verde agua #1BAF7A	Tercer tono de la paleta categórica, distinguible del azul y del naranja.
Magnético	Ámbar #EDA100	Cuarto tono; categoría minoritaria.
Otros formatos	Gris #9B9A94	Neutro a propósito: «Otros» no debe competir por atención.
Banner y títulos	Azul marino #0D366B / tinta #1B2433	Análogos al azul de los datos: armonía monocromática.
Fondo	#F4F6F9 con tarjetas blancas	Fondo claro de estilo SaaS; las tarjetas separan bloques sin líneas pesadas.

- **El color sigue a la entidad, no al gráfico:** cada formato conserva su color en todas las páginas, así el usuario lo reconoce sin volver a leer la leyenda.
- **Validación de daltonismo:** la paleta se verificó con simulación de protanopía, deuteranopía y tritanopía. La separación mínima entre colores adyacentes es $\Delta E \approx 9{,}1$ (objetivo ≥ 8). Los textos van en gris y tinta, nunca en el color de la serie, y todos los gráficos tienen leyenda o etiqueta directa.
- **Un solo color en gráficos de una serie** (rankings, histograma, dispersión): agregar colores sin significado confundiría al lector.
- **Sin rojo y verde para datos:** se reservan para estados (bueno/malo) y no se mezclan con las categorías.

SECCIÓN 11

Justificación de cada gráfico

Cada gráfico se eligió según el **tipo de pregunta estadística** que responde, siguiendo el selector de gráficos de Andrew Abela. Esa taxonomía clasifica las preguntas en cuatro tipos: **comparación**, **composición**, **distribución** y **relación**. El dashboard cubre los cuatro.

Gráfico	Pregunta de negocio	Tipo (Abela)	Por qué este gráfico
Tarjetas KPI	¿Cuál es la magnitud del catálogo?	Valor único	Un número clave no necesita eje; la tarjeta se lee en un segundo.
Área apilada por año y formato	¿Cómo creció la producción y cómo cambió su mezcla?	Composición en el tiempo (muchos períodos)	Muestra a la vez el total (altura) y la composición (capas) en 76 años.
Líneas Digital vs CD	¿Cuándo el digital superó al físico?	Comparación en el tiempo (pocas series)	Dos líneas en el mismo eje de % muestran el cruce con precisión.
Barras horizontales (países, tipo de artista, idiomas)	¿Quién produce más?	Comparación entre categorías	La longitud es el atributo que mejor se compara; la orientación horizontal deja leer nombres largos; se ordenan de mayor a menor.
Histograma de duración	¿Cuánto dura una canción típica?	Distribución	Las barras contiguas representan clases continuas; muestran forma, moda y asimetría.
Columnas 100 % apiladas por década	¿Qué formato dominó cada época?	Composición relativa (pocos períodos)	Normaliza cada década al 100 % para comparar proporciones aunque el volumen cambie.
Dispersión por país (eje X logarítmico)	¿Más volumen implica más digitalización?	Relación entre dos variables	Cada punto es un país; la nube revela si existe asociación y muestra los casos atípicos.
Tabla Top 20 artistas	¿Cuáles son los valores exactos de los principales artistas?	Consulta de detalle	Cuando se necesitan cifras exactas de varias métricas, la tabla es más precisa que un gráfico.

Gráficos descartados y por qué

- **Gráfico de torta:** el ojo compara mal ángulos y áreas; con cinco formatos y diferencias pequeñas, las barras o el 100 % apilado son más precisos.
- **Doble eje Y:** dos escalas en un mismo gráfico sugieren correlaciones que dependen de cómo se elige cada escala. Cada medida va en su propio gráfico.
- **Mapa coroplético:** el país dominante (Estados Unidos) saturaría la escala, y las áreas grandes con pocos datos (por ejemplo, Rusia o Canadá) distorsionan la percepción. El ranking en barras es más honesto.
- **Promedio de duración por década (línea):** se reemplazó por el histograma, que muestra la distribución completa y no solo su centro.

Evidencia: transición digital

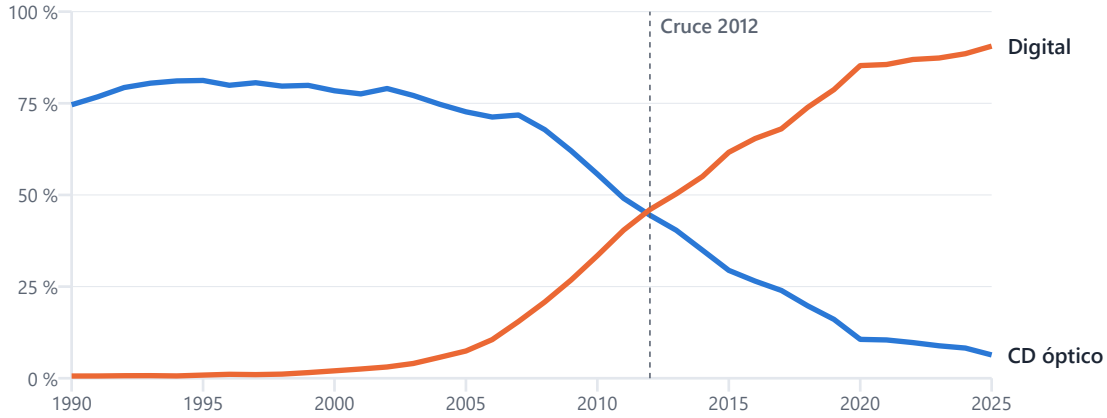


Figura 2. Participación de lanzamientos por año, Digital vs CD óptico (1990–2025). Datos en vivo de gold.

Evidencia: principales países

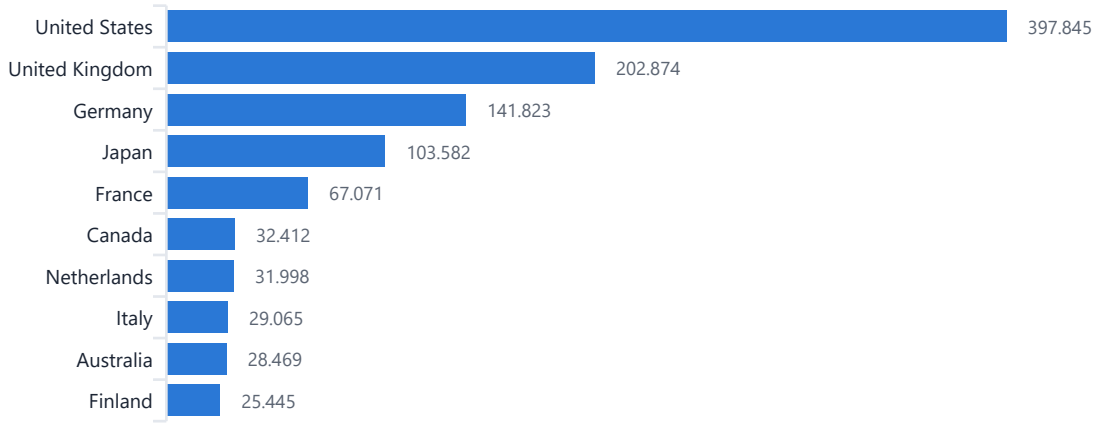


Figura 3. Top 10 países por lanzamientos únicos (solo áreas de tipo País).

SECCIÓN 12

Fundamentos estadísticos

Estadística	Fórmula / medida	Por qué se usa
Total (suma)	SUM(lanzamientos_total)	Magnitud aditiva del catálogo; válida en cualquier filtro.
Conteo distinto	DISTINCTCOUNT(artista_key)	Artistas únicos: no se suma, se cuenta sobre el contexto filtrado.
Proporción	DIVIDE(parte, total)	Coberturas y participaciones (ISRC, digital, pistas largas).
Media ponderada	Σ duración / Σ pistas con duración	Evita sesgo del promedio de promedios.
Frecuencia relativa	pistas en banda / pistas totales	Base del histograma; permite comparar selecciones de distinto tamaño.
Moda y mediana	banda más frecuente / banda del percentil 50	Tendencia central robusta frente a valores extremos.
Correlación de Pearson (r)	corr(año, duración media)	Mide la fuerza y el signo de una relación lineal entre −1 y 1.

Estadística	Fórmula / medida	Por qué se usa
Pendiente (regresión lineal)	regr_slope(duración, año)	Traduce la correlación a segundos por año.
Escala logarítmica	log10(lanzamientos) en el eje X	Variables con varios órdenes de magnitud (Top 30: de 3.965 a 397.845).

Distribución de la duración (histograma)

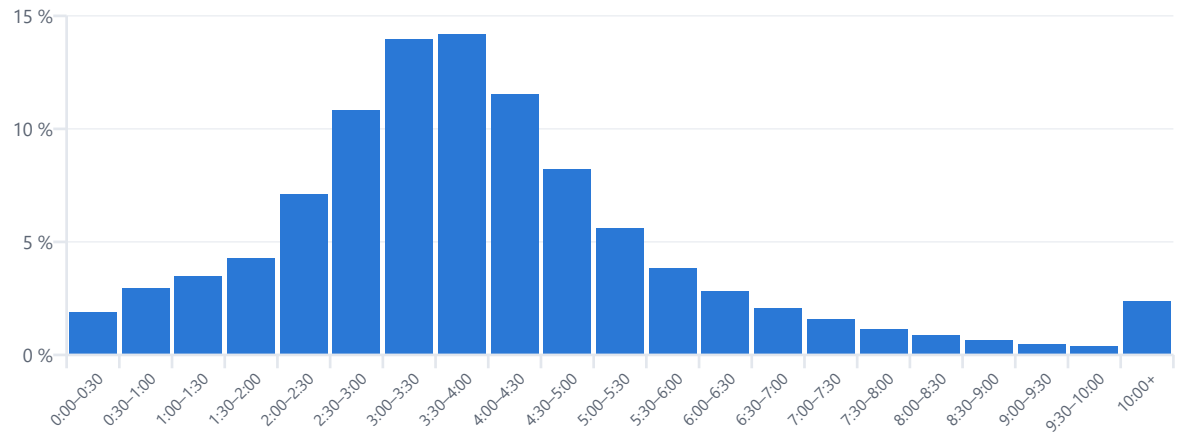


Figura 4. Frecuencia relativa de pistas por banda de duración de 30 s (excluye pistas sin duración).

- **Moda:** 3:30–4:00 (14,2 % de las pistas). **Mediana:** banda 3:30–4:00. **Media:** 4:08 min.
- **Asimetría positiva:** la media es mayor que la mediana porque una cola de pistas muy largas (música clásica, mezclas, grabaciones en vivo) la desplaza hacia la derecha; el 2,4 % supera los 10 minutos.
- **Lectura de negocio:** el formato estándar de canción popular (3 a 4,5 minutos) concentra la mayor parte del catálogo.

Correlación año–duración (RF05)

Período	r de Pearson	Pendiente	Años (n)	Interpretación
1950–2025	0,89	1,02 s/año	76	Fuerte y positiva: las canciones se alargan.
1990–2025	0,64	0,40 s/año	36	Moderada y positiva: las canciones se alargan.
2013–2025	-0,57	-1,01 s/año	13	Moderada y negativa: las canciones se acortan.

Lectura honesta del resultado

La hipótesis original de RF05 («demostrar el acortamiento en la era del streaming») **se cumple solo parcialmente**. En el largo plazo la relación es positiva; el acortamiento aparece desde que el digital domina. Además, la correlación usa medias anuales (n = 13 en el período reciente), **no prueba causalidad** y se calcula sobre el subconjunto cargado. Se presenta como evidencia descriptiva, no como conclusión definitiva.

SECCIÓN 13

Trazabilidad de requisitos

Requisito	Dónde se responde	Estado
RF01 · Ranking Top N	Tabla Top 20 artistas, Top 10 países; segmentadores de país y década	Cubierto
RF02 · Métricas por formato e idioma	KPI de duración con segmentador de idioma; Top idiomas; mezcla de formatos	Cubierto
RF03 · Drill-down geográfico y temporal	Segmentadores de año, década y país; jerarquías no publicadas como drill-down	Parcial
RF04 · Digital vs físico y pistas largas	Líneas Digital vs CD, área apilada, KPI % pistas > 5 min	Cubierto
RF05 · Correlación año–duración	Sección 12 (SQL corr()); histograma de duración en el dashboard	Cubierto en documento
RF06 · Formalización ISRC	KPI de cobertura ISRC; columna ISRC en Top 20 con segmentadores de país y tipo	Parcial
RF07 · Densidad de pistas	KPI de pistas por lanzamiento; pistas por soporte no visualizado	Parcial
RF08 · Artistas emergentes	No incluido en el dashboard actual	Pendiente

SECCIÓN 14

Limitaciones y trabajo futuro

- **Cobertura parcial:** solo se cargaron las primeras 15 M de pistas del volcado; no es una muestra aleatoria.
- **Asignación a la primera pista:** un lanzamiento con varios artistas o formatos se atribuye a los de su primera pista.
- **País con respaldo:** si el lanzamiento no tiene país, se usa el área de origen del artista.
- **Nombres de idioma en inglés:** provienen del catálogo oficial de MusicBrainz; traducirlos a mano fue la causa del defecto 3.
- **Histograma sin artista:** el segmentador de tipo de artista no lo filtra.
- **Trabajo futuro:** publicar jerarquías de drill-down (siglo → década → año; país → tipo de área → área), completar RF06–RF08 y cargar el volcado completo de pistas.

SECCIÓN 15

Preguntas probables del profesor

P: ¿Por qué un esquema en estrella y no un copo de nieve?

R: Porque minimiza joins, es más fácil de entender para negocio y es el modelo que mejor aprovecha Power BI. Las jerarquías (país → área, año → mes) se desnormalizan dentro de cada dimensión.

P: ¿Cuál es el grano y por qué ese?

R: Día × artista × perfil × país × formato × idioma. Es el nivel más fino que necesitan las preguntas; desde ahí cualquier agregación (año, década, país) es una simple suma.

P: ¿Son realmente aditivas todas sus métricas?

R: Sí, después de la corrección. Los conteos de lanzamientos, soportes y grabaciones se asignan a una sola fila; por eso la suma coincide con el conteo distinto en Silver. Los artistas activos son un conteo distinto y por eso se calculan como medida DISTINCTCOUNT, no como columna sumable.

P: ¿Qué es la fila con clave 0?

R: Es el miembro desconocido de cada dimensión. Garantiza cero huérfanos: los totales del hecho siempre cuadran y el usuario ve explícitamente cuánto dato falta.

P: ¿Por qué no usó un gráfico de torta para los formatos?

R: Porque los humanos comparamos longitudes con mucha más precisión que ángulos. Para composición usé área apilada y columnas 100 %, que además muestran la evolución en el tiempo.

P: ¿Por qué el eje X de la dispersión es logarítmico?

R: Porque los lanzamientos por país van de miles a cientos de miles. En escala lineal, Estados Unidos aplasta al resto en una esquina; la escala logarítmica muestra todos los países con la misma resolución relativa.

P: ¿Cómo sabe que los números son correctos?

R: Por controles automáticos: integridad referencial (0 huérfanos), conciliación de lanzamientos, soportes y pistas contra Silver, y validación de las medidas con consultas DAX independientes.

P: ¿La correlación de Pearson prueba que el streaming acortó las canciones?

R: No. Pearson mide asociación lineal, no causalidad, y se calculó sobre medias anuales. Los datos muestran alargamiento a largo plazo y un leve acortamiento en el período reciente; lo presento como evidencia descriptiva.

SECCIÓN 16

Guion para la junta directiva

Duración estimada: **8 minutos**. Tono: un ingeniero de datos que traduce hallazgos técnicos en decisiones de negocio. Las frases en cursiva son para decir; las indicaciones entre corchetes son acciones en pantalla.

0:00 – 0:45 · Apertura
[Página Resumen ejecutivo, sin filtros]

> *«Buenos días. En los próximos minutos les voy a mostrar qué nos dicen quince millones de pistas de producción musical sobre hacia dónde va la industria, y qué decisiones podemos tomar con eso. Todo lo que van a ver sale de un Data Warehouse que construimos y verificamos sobre el catálogo público de MusicBrainz.»*

0:45 – 1:45 · El tamaño del catálogo
[Señalar la fila de tarjetas KPI]

> *«Estamos hablando de 1.728.603 lanzamientos, 15.000.000 pistas y casi 690.000 artistas activos. Hay dos indicadores que quiero que retengan: hoy solo el 22,4 % de las pistas tiene código ISRC, el identificador que permite rastrear regalías, y el 28,2 % de toda la historia del catálogo ya es digital.»*

1:45 – 3:15 · La gran transición
[Señalar el área apilada y luego la línea Digital vs CD]

«Este gráfico cuenta la historia de 75 años de música. La capa azul es el CD, que dominó desde los noventa. La naranja es el digital. Fíjense en la línea de la derecha: en 2012 el digital superó al CD, y desde entonces la brecha no dejó de crecer. En 2025, 90,6 % de los lanzamientos son digitales y apenas 6,4 % salen en CD. Para nosotros esto significa que la distribución digital ya no es un canal alternativo: es el canal.»

3:15 – 4:15 · Dónde se produce
[Señalar Top 10 países y tipo de artista]

«La producción está concentrada: Estados Unidos, Reino Unido y Alemania encabezan el ranking. Los solistas y las bandas explican casi toda la producción. Si buscamos alianzas de catálogo, estos son los mercados con más volumen.»

4:15 – 5:30 · Qué caracteriza a la música
[Cambiar a Análisis detallado; señalar el histograma]

«Este histograma muestra cuánto dura una canción. La mayoría está entre tres y cuatro minutos y medio, con el pico en 3:30–4:00. Es el formato que el mercado prefiere. Y algo interesante: tras décadas de canciones cada vez más largas, desde que domina el streaming la duración empezó a bajar levemente. Lo seguiremos monitoreando.»

5:30 – 6:30 · Volumen no es lo mismo que digitalización
[Señalar la dispersión por país]

«Cada punto es un país. Si más volumen significara más digitalización, veríamos los puntos subir hacia la derecha, y no pasa. Corea del Sur, con poco volumen, tiene 41,7 % de lanzamientos digitales. Esos mercados pequeños y muy digitales son una oportunidad de entrada con menos competencia.»

6:30 – 7:15 · Por qué pueden confiar en estos números
[Sin cambio de pantalla]

«Antes de traerles este tablero lo auditamos. Encontramos y corregimos errores reales, como un conteo que duplicaba lanzamientos y un catálogo de idiomas mal mapeado. Hoy cada cifra se concilia automáticamente con la fuente y no hay registros huérfanos.»

7:15 – 8:00 · Recomendaciones y cierre
[Volver al Resumen ejecutivo]

«Tres recomendaciones. Primero, priorizar la distribución digital, que ya es el canal principal. Segundo, impulsar el registro de códigos ISRC: con solo una de cada cinco pistas identificada, estamos dejando regalías sin rastrear. Tercero, explorar mercados pequeños y muy digitalizados. El tablero queda disponible para que cada área filtre por su país, formato o época. ¿Preguntas?»

Consejos de presentación

Hablar de decisiones, no de herramientas (la junta no necesita oír «DAX» ni «VertiPaq»). Apoyar cada afirmación en un gráfico visible. Decir los números redondeados y con contexto («una de cada cinco»). Cerrar con una acción concreta.

ANEXO A

Catálogo de medidas DAX

Medida	Expresión DAX
Total Lanzamientos	`SUM('gold fact_produccion_musical'[lanzamientos_total])`
Total Soportes	`SUM('gold fact_produccion_musical'[soportes_total])`
Total Pistas	`SUM('gold fact_produccion_musical'[pistas_total])`
Artistas Activos	`DISTINCTCOUNT('gold fact_produccion_musical'[artista_key])`
Pistas por Lanzamiento	`DIVIDE([Total Pistas], [Total Lanzamientos])`
% del Total Lanzamientos	`DIVIDE([Total Lanzamientos], CALCULATE([Total Lanzamientos], ALLSELECTED()))`
Duracion Total (Horas)	`DIVIDE(SUM('gold fact_produccion_musical'[duracion_total_minutos]), 60)`
Duracion Promedio por Pista (min)	`DIVIDE(SUM(...[duracion_total_segundos]), SUM(...[pistas_completas_total])) / 60`
Pistas con ISRC	`SUM('gold fact_produccion_musical'[pistas_con_isrc_total])`
Cobertura ISRC %	`DIVIDE([Pistas con ISRC], [Total Pistas])`
Pistas Largas (>5 min)	`SUM('gold fact_produccion_musical'[pistas_largas_total])`
% Pistas Largas	`DIVIDE([Pistas Largas (>5 min)], [Total Pistas])`
Lanzamientos Digitales	`CALCULATE([Total Lanzamientos], 'gold dim_formato'[categoria_formato] = "Digital / Streaming")`
Lanzamientos Vinilo	`CALCULATE([Total Lanzamientos], 'gold dim_formato'[categoria_formato] = "Físico / Vinilo")`
Lanzamientos CD Optico	`CALCULATE([Total Lanzamientos], 'gold dim_formato'[categoria_formato] = "Físico / Óptico")`
Participacion Digital %	`DIVIDE([Lanzamientos Digitales], [Total Lanzamientos])`
Participacion Vinilo %	`DIVIDE([Lanzamientos Vinilo], [Total Lanzamientos])`
Participacion CD Optico %	`DIVIDE([Lanzamientos CD Optico], [Total Lanzamientos])`
Lanzamientos Anio Anterior	`VAR a = SELECTEDVALUE('gold dim_fecha'[anio]) RETURN IF(a > 1900, CALCULATE([Total Lanzamientos], REMOVEFILTERS('gold dim_fecha'), 'gold dim_fecha'[anio] = a - 1))`
Variacion Interanual %	`DIVIDE([Total Lanzamientos] - [Lanzamientos Anio Anterior], [Lanzamientos Anio Anterior])`
Pistas (Distribucion)	`SUM('gold fact_distribucion_duracion'[pistas_total])`
% Pistas (Distribucion)	`DIVIDE([Pistas (Distribucion)], CALCULATE([Pistas (Distribucion)], ALLSELECTED('gold dim_rango_duracion')))`

ANEXO B

Glosario

Término	Definición
Grano	Nivel de detalle que representa una fila de la tabla de hechos.
Dimensión conformada	Dimensión compartida por varios hechos con el mismo significado y claves.
Clave subrogada	Identificador entero generado por el DW, independiente de la clave de la fuente.
Métrica aditiva	Valor numérico que se puede sumar correctamente en cualquier dimensión.
SCD Tipo 1	Actualización de una dimensión que sobrescribe el valor anterior sin guardar historial.
Junk / profile dimension	Dimensión que agrupa combinaciones de atributos de baja cardinalidad.
Band dimension	Dimensión que discretiza una medida continua en rangos (bandas).
ISRC	International Standard Recording Code: identificador único de una grabación, usado para regalías.
Partition pruning	Capacidad del motor de descartar particiones que no cumplen el filtro de la consulta.
DAX	Lenguaje de fórmulas del modelo semántico de Power BI.