DWMusicBrainz · Bases de Datos Avanzadas

Defensa de la capa Gold y del dashboard

Versión 2: Databricks, volcado completo
58.809.976 pistas

Juan Sebastián Rincón Farelo
Integrantes: Juan Rincón, Sebastián Russo, Jesús Figueroa
Docente: Amilkar Sierra Romano
Ingeniería de Sistemas · Universidad Popular del Cesar
Valledupar, noviembre de 2026

Índice

Resumen ejecutivo 3

Hallazgos principales . . . 3

Contexto, arquitectura y alcance 4

Alcance de los datos . . . 4

Diseño dimensional (metodología Kimball) 5

Decisiones de diseño clave . . . 5

Tablas de hechos 6

Regla de fecha y territorio . . . 6

Ejemplo real . . . 6

Dimensiones conformadas 7

Hecho de distribución y dimensión de bandas 7

Diseño físico y rendimiento 8

Calidad de datos y hallazgos de auditoría 9

Datos especiales tratados en el dashboard . . . 9

Dashboard en Databricks AI/BI 10

Diferencias funcionales frente a Power BI . . . 12

Diseño del dashboard y teoría del color 12

Principios aplicados . . . 12

Validación de la paleta . . . 13

Justificación de cada gráfico 14

Gráficos descartados . . . 14

Fundamentos estadísticos 16

Distribución de la duración . . . 16

Correlación año-duración (RF05) . . . 17

Trazabilidad de requisitos 17

Limitaciones y trabajo futuro 18

Preguntas probables del profesor 19

Guion para la mesa directiva 20

Medidas del dashboard en SQL 21

Glosario 22

Sección 1

Resumen ejecutivo

La capa **Gold** de DWMusicBrainz sobre **Databricks** transforma el modelo normalizado de Silver en un **modelo dimensional en estrella**, ahora con el volcado completo de MusicBrainz. Encima se construyó un **dashboard AI/BI de 3 páginas**. Esta defensa reemplaza a la de la entrega con 15 M de pistas: las cifras y varias conclusiones cambiaron.

5.890.921 Lanzamientos únicos	**58.809.976** Pistas analizadas	**1.633.826** Artistas activos	**29,1 %** Cobertura ISRC
49,5 % Participación digital histórica	**4:14** Duración media (m:ss)	**10,0** Pistas por lanzamiento	**3.841.809** Horas de audio catalogadas

Hallazgos principales

- **Transición de formato:** digital superó a **óptico** en **2011**. En 2025 digital representa 90,7 % de los lanzamientos con fecha y óptico 6,4 %. Óptico incluye CD, DVD y formatos similares; por eso no se habla solo de CD.
- **Duración:** entre 1950 y 2025 la duración media crece con el año ($r = +0{,}917$). Entre 2013 y 2025 el signo se invierte, pero la evidencia es débil: la relación no es significativa ($r = -0{,}343$, $n = 13$). La tesis de «canciones más cortas por el streaming» no queda demostrada.
- **Distribución:** la moda está en 3:00–3:30 (14,4 %) y la mediana en 3:30–4:00. La media es 4:14, con cola larga a la derecha.
- **Volumen y digitalización:** en el Top 30 de países no hay relación clara entre ambos ($r = -0{,}09$ con el logaritmo del volumen). Corea del Sur llega a 58,5 % con 32.739 lanzamientos.
- **Gobierno del dato:** 116 de 116 reglas bloqueantes aprobadas. Aun así, dos errores graves pasaron las primeras validaciones y se detectaron inspeccionando resultados (sección 8).

Sección 2

Contexto, arquitectura y alcance

El volcado oficial se carga en Databricks: un Volume guarda los archivos, **Bronze** conserva una copia fiel como texto, **Silver** aplica tipos, escapes y control de calidad, y **Gold** construye el modelo en español. Lakeflow Jobs orquesta el proceso. El volcado usado es `20261104-002222`, Schema Sequence 31.

Capa	Propósito	Modelo	Objetos principales
Volume	Archivos originales	TSV	11 tablas y 6 catálogos oficiales
Bronze	Copia fiel, sin interpretar	Delta, todo texto	11 tablas, 142.969.789 filas
Silver	Datos tipados y limpios	Relacional 3FN en Delta	142.969.789 filas en 11 tablas, más catálogos
Gold	Consumo analítico	Estrella de Kimball	3 hechos, 7 dimensiones y 4 tablas mv_*
Consumo	Dashboard	Databricks AI/BI	3 páginas, 45 widgets, 9 datasets

Alcance de los datos

- Se procesan **58.809.976 pistas**, el volcado completo. La carga anterior tomaba las primeras 15 M por orden de archivo y no era una muestra aleatoria.
- Hay 5.890.921 lanzamientos con pistas de 5.903.902 en Silver. El resto no tiene pistas asociadas.
- Existen 311.754 lanzamientos sin fecha válida en la clave 0 y 1.453.024 pistas sin geografía.

Sección 3

Diseño dimensional (metodología Kimball)

El modelo sigue los cuatro pasos de Kimball. El grano es la decisión que más cambió frente a la entrega anterior.

Paso	Decisión	Justificación
1. Proceso	Publicación de pistas en lanzamientos	Es el evento medible que responde RF01 a RF08.
2. Grano	Atómico: una fila por pista en fact_pista	Conserva el detalle completo y cumple el requisito de más de 50 M de registros.
3. Dimensiones	Fecha, artista, lanzamiento, geografía, formato, idioma y rango de duración	Son los ejes de análisis pedidos.
4. Hechos	Banderas en fact_pista y métricas aditivas en los agregados	Permiten sumar sin duplicar en cualquier nivel.

Declaración del grano

«Una fila de **fact_pista** representa una pista dentro de un soporte de un lanzamiento.» «Una fila de **fact_produccion_musical** consolida las pistas de un día para una combinación de artista, perfil de lanzamiento, geografía, formato e idioma.»

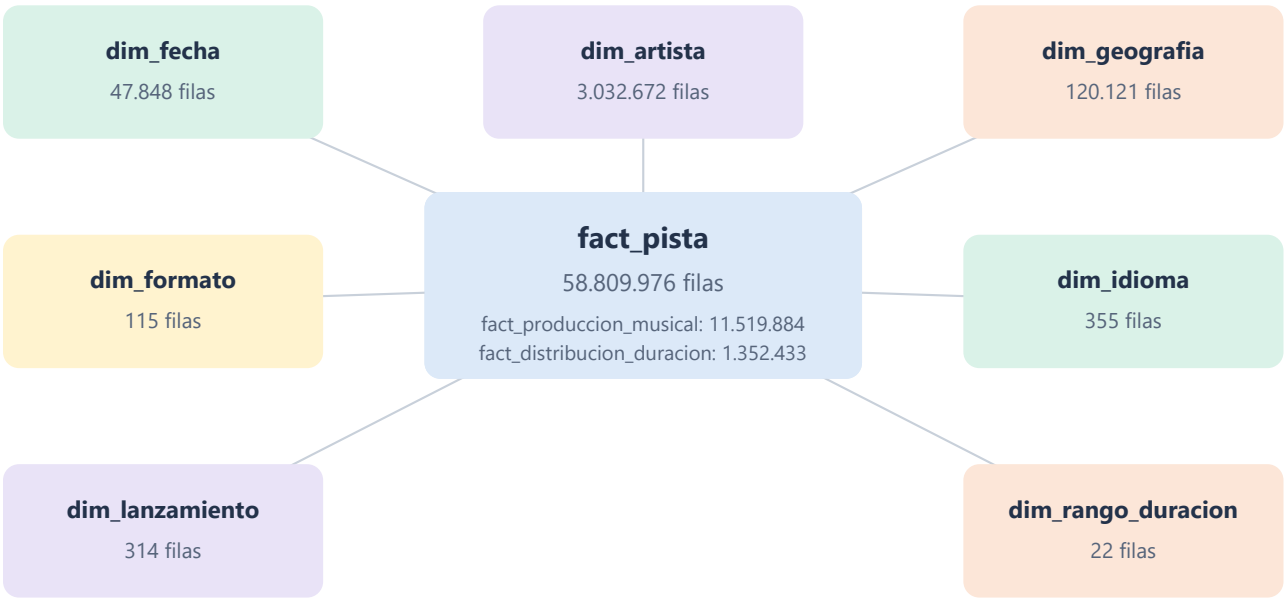


Figura 1. Hechos de Gold y dimensiones conformadas, con filas actuales.

Decisiones de diseño clave

- **Dos niveles:** fact_pista guarda el detalle; los hechos agregados dan respuestas rápidas al dashboard.
- **Claves sustitutas:** enteros secuenciales ordenados por clave natural; aíslan el modelo de la fuente.
- **Fila cero:** cada dimensión tiene una fila para el valor desconocido, así el hecho nunca pierde filas.
- **dim_lanzamiento como dimensión de perfil:** 314 combinaciones de estado, empaque y calidad, no una fila por lanzamiento. El identificador del lanzamiento queda en fact_pista.

Sección 4

Tablas de hechos

fact_pista tiene 58.809.976 filas. **fact_produccion_musical** tiene 11.519.884 filas y 11 métricas aditivas.

Métrica agregada	Cálculo	Significado
lanzamientos_total	1 en la primera pista del lanzamiento	Lanzamientos únicos
soportes_total	1 en la primera pista del soporte	Discos o medios únicos
pistas_total	Conteo de pistas	Pistas publicadas
grabaciones_unicas_total	1 en la primera aparición	Grabaciones distintas
duracion_total_*	Suma de duración	Tiempo en ms, segundos y minutos
pistas_con_isrc_total	Suma de la bandera tiene_isrc	Pistas con código ISRC
pistas_largas_total	Pistas de más de 5 minutos	Pistas largas
pistas_video_total	Suma de la bandera es_video	Pistas de video
pistas_completas_total	Pistas con duración mayor que 0	Denominador de promedios

Por qué los conteos son aditivos

Un conteo distinto por fila no es aditivo: si un lanzamiento aparece en dos filas, la suma lo cuenta dos veces. Por eso cada lanzamiento, soporte y grabación se asigna a una sola fila, la de su primera pista. En Databricks se calcula con `min(struct(...))` en lugar de `ROW_NUMBER`. Así, las sumas dan 5.890.921 lanzamientos y 6.463.097 soportes, iguales a los conteos distintos.

Regla de fecha y territorio

- La fecha es la más antigua del lanzamiento, con prioridad para eventos con país. Si no es válida, va a la clave 0. No se imputa con otros datos.
- Si un solo país tiene esa fecha, se conserva. Con 10 o más países empatados pasa a [Worldwide]; con 2 a 9, al país con más lanzamientos. Esta regla corrige el caso Afghanistan (sección 8).
- Los años válidos van de 1900 a 2030. Las fechas anteriores a 1900 pasan a «sin fecha».

Ejemplo real

El lanzamiento 1438346 de Shakira ocupa **33 filas** en fact_pista, en 3 soportes, con 28 pistas con ISRC. Solo 1 fila suma el lanzamiento. En la carga recortada aparecía con 21 pistas y 2 soportes, algo consistente con el corte por líneas del archivo.

Sección 5

Dimensiones conformadas

Dimensión	Filas	Atributos principales	Uso
dim_fecha	47.848	anio, trimestre, mes, decada, siglo	Rangos y series de tiempo
dim_artista	3.032.672	nombre_artista, tipo_artista, genero, nombre_pais, anio_inicio	Tipo de artista y rankings
dim_lanzamiento	314	estado_lanzamiento, tipo_empaque, calidad_datos	Filtro de estado y densidad
dim_formato	115	nombre_formato, categoria_formato	Mezcla y participación digital
dim_geografia	120.121	nombre_area, tipo_area, nombre_pais	Rankings y dispersión
dim_idioma	355	nombre_idioma, codigo_iso	Top idiomas
dim_rango_duracion	22	etiqueta_rango, limites en segundos	Histograma

- **Etiquetas:** cada ID se resuelve con los catálogos oficiales del volcado. Las reglas V08 a V11 bloquean el job si una etiqueta difiere.
- **Calidad:** 5.875.755 lanzamientos tienen el valor por defecto −1 y figuran como «Sin calificar». Esa cifra no significa calidad baja.
- **Calidad y catálogo:** la calidad no viene como catálogo en el volcado. Sus nombres (0 Baja, 1 Normal, 2 Alta) y la asignación de categorías de formato son criterio del proyecto.
- **Fila 0 de dim_lanzamiento:** la ocupan 770 lanzamientos reales de calidad 0, sin estado ni empaque; no es un desconocido puro.
- **SCD Tipo 1:** las dimensiones se reconstruyen en cada carga; el análisis no requiere historial de atributos.

Sección 6

Hecho de distribución y dimensión de bandas

El histograma necesita contar pistas por duración. Para eso existe **fact_distribucion_duracion**, con 1.352.433 filas y grano año × formato × idioma × geografía × banda.

- **dim_rango_duracion:** 20 bandas de 30 s entre 0:00 y 10:00, una banda abierta «10:00+» y la clave 0 «Sin duración».
- **Conciliación:** las bandas con duración suman 54.468.610 pistas, igual a las pistas con duración del hecho agregado.
- **Ancho de 30 s:** la regla de Sturges con unas 54 M de observaciones sugiere alrededor de 27 clases, cercano a las 21 usadas, y 30 s es fácil de leer.
- **Sin artista:** el grano no incluye artista, así que el filtro de tipo de artista no afecta al histograma. Es una limitación conocida.

Sección 7

Diseño físico y rendimiento

Objeto	Filas	Tamaño	Archivos	Clustering
fact_pista	58.809.976	0,77 GB	16	fecha_key, artista_key
fact_produccion_musical	11.519.884	0,22 GB	4	fecha_key, artista_key
fact_distribucion_duracion	1.352.433	11 MB	1	fecha_key, rango_duracion_key
dim_artista	3.032.672	0,12 GB	2	—
mv_analitica_artistas	1.633.826	39 MB	1	artista_key

- **Delta Lake:** columnar, comprimido y con historial. El historial permitió comparar versiones con *time travel* y probar que las claves no cambiaron.
- **Liquid clustering:** reemplaza particiones e índices. Se aplica en los hechos sobre fecha_key y artista_key. Su beneficio **no se midió** contra una tabla sin clustering.
- **Tablas agregadas:** sostienen el dashboard. En pruebas por la API, el warehouse 2X-Small respondió entre 1,3 y 3,1 s.
- **Advertencia:** esas pruebas fueron consultas una a la vez, no varios usuarios simultáneos, y las tablas pueden tardar más al abrir la página si el warehouse estaba apagado.

Sección 8

Calidad de datos y hallazgos de auditoría

El registro `meta.data_quality_log` tiene **116 de 116 reglas bloqueantes aprobadas**: 94 de la validación final y 22 de Silver. También registra 10 indicadores informativos. Las reglas no reemplazan la revisión: dos de los errores siguientes pasaron las primeras validaciones.

#	Defecto	Impacto	Corrección	Detección
1	Conteos distintos por fila que luego se sumaban (entrega anterior)	KPI principal inflado	Asignación a la primera pista	Conciliación
2	Orden de columnas de medium invertido en el DDL anterior	edits_pending y track_count cruzados	Orden real del volcado	Inspección de archivos
3	Etiquetas escritas a mano por ID	5.875.755 lanzamientos «Baja»; 76.524 ciudades como «Condado»	Catálogos oficiales y reglas V08 a V11	Inspección, no por reglas
4	Empates de fecha resueltos por menor ID de país	Afghanistan con 32.206 lanzamientos	Regla nueva y validación V12	Inspección, no por reglas
5	29 de febrero convertido en día 1	Fechas alteradas	Se conserva la fecha real	Revisión de código
6	artist_credit usado como artist.id	Riesgo de artista incorrecto	Sin esa asignación	Revisión de código

Caso de estudio: un dato raro era un error de lógica

Afghanistan tiene el ID de área 1. Cuando un lanzamiento se publicaba en muchos países con la misma fecha, el desempate elegía el menor ID. Por eso reunía 32.206 lanzamientos de 23.640 artistas. Con la regla nueva bajó a 104 y [Worldwide] subió de 2.050.347 a 2.098.419. Los totales no cambiaron y 639.777 pistas cambiaron de área.

Datos especiales tratados en el dashboard

- Artistas como [unknown] o [no artist] se excluyen de los rankings: no son artistas reales.
- El ranking de países usa solo áreas de tipo País. [Worldwide] se muestra aparte, como bloque multiterritorial.
- Las series terminan en 2025: 2026 está incompleto y hay 2.716 pistas con años posteriores a 2026.

Sección 9

Dashboard en Databricks AI/BI

El dashboard tiene 3 páginas, 45 widgets y 9 datasets. AI/BI no usa DAX: las medidas se escriben como expresiones SQL sobre cada dataset (Anexo A). Corre sobre el warehouse, sin importar datos al equipo del usuario.

Página	Pregunta que responde	Contenido
Resumen ejecutivo	¿Cuánto y cómo cambió la industria?	5 KPI, área por formato, cuota digital y rankings
Análisis detallado	¿Qué la caracteriza por época, país y artista?	4 KPI, histograma, mezcla, Top 20 y dispersión
Calidad y catálogo	¿Qué tan formalizado y denso es el catálogo?	4 KPI, tiempo, áreas, empaque, mapa de calor y emergentes



Figura 2. Página Resumen ejecutivo publicada en Databricks.

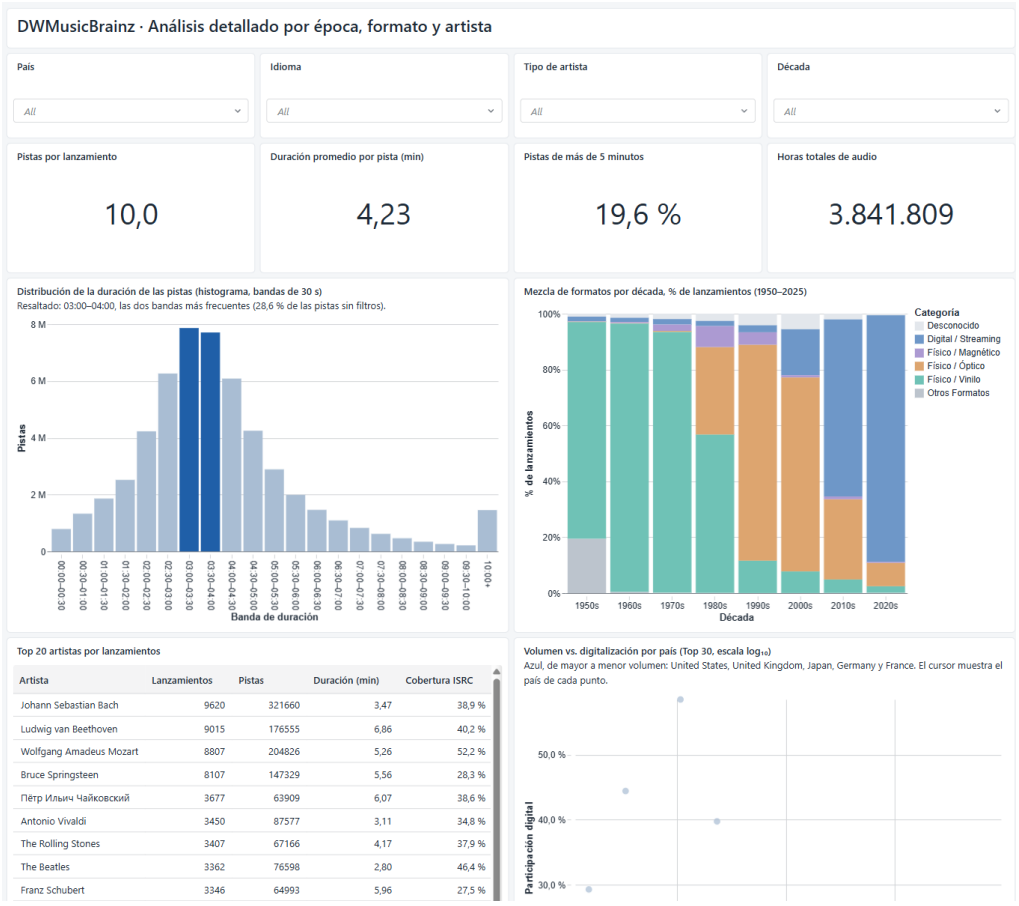


Figura 3. Página Análisis detallado.

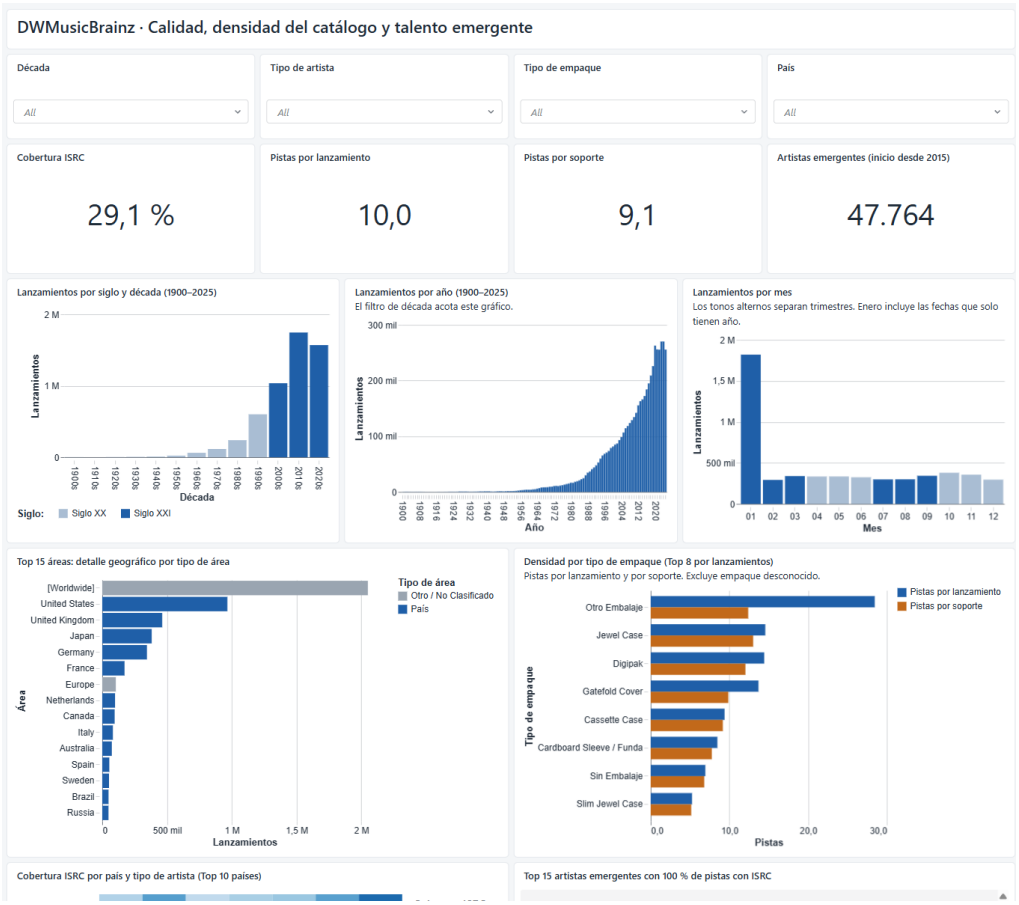


Figura 4. Página Calidad y catálogo.



Drill-down temporal: siglo, década, año, trimestre y mes
Clic derecho sobre un valor y luego Drill down. Para volver, Drill up en el encabezado.

Siglo	Década	Año	Trimestre	Mes	Lanzamie...
Siglo XX	1900s	1900	Q1	01	30
			Q2	05	1
				06	27
			Q3	08	20
				09	19
			Q4	10	27
				11	10
				12	10
		1901	Q1	01	41
				02	13
				03	13
			Q2	04	18
				05	23
				06	21
			Q3	07	14

Drill-down geográfico: país, tipo de área y área
Clic derecho sobre un valor y luego Drill down. Para volver, Drill up en el encabezado.

País	Tipo de á...	Área	Lanzamie...
Afghanistan	País	Afghanistan	104
Åland Islands	País	Åland Islands	17
Albania	País	Albania	224
Algeria	País	Algeria	360
American Samoa	País	American Samoa	11
Andorra	País	Andorra	103
Angola	País	Angola	201
Anguilla	País	Anguilla	20
Antarctica	País	Antarctica	25
Antigua and Barbuda	País	Antigua and Barbuda	35
Argentina	País	Argentina	19471
Armenia	País	Armenia	289
Aruba	País	Aruba	16
Australia	País	Australia	72685
Austria	País	Austria	24645

Figura 4b. Tablas dinámicas de drill-down temporal y geográfico.

Diferencias funcionales frente a Power BI

- **Drill-down:** disponible con clic derecho en dos tablas dinámicas: de siglo a mes, y de país a área. Filtra además el resto de la página, y Drill up vuelve al nivel anterior.
- **Clic para filtrar:** hacer clic en una barra filtra los gráficos del mismo dataset, no los de otros datasets.
- **Top N:** se calcula sobre todos los datos y no se recalcula al filtrar.
- **Histograma:** muestra pistas por banda, no porcentaje.
- **Dispersión:** el eje X es LOG10 calculado en SQL y no responde a filtros.
- **Tablas:** no muestran separador de miles; se probaron tres formatos sin éxito.

Sección 10

Diseño del dashboard y teoría del color

Principios aplicados

- **Regla 3-30-300:** en 3 segundos se entiende el propósito, en 30 los hallazgos y en 300 se explora el detalle.
- **Jerarquía visual (Stephen Few):** arriba los filtros, luego KPI, tendencia y desglose.
- **Relación datos-tinta (Edward Tufte):** sin efectos 3D ni sombras; cuadrícula tenue.
- **Una pregunta por página:** cada página tiene un propósito distinto.

Elemento	Color	Razón
Mensaje principal	Azul #1F5FA8	Digital o líder del ranking; concentra la atención.
Contraste	Naranja #C2691A	Complementario del azul: separa digital de óptico.
Otras categorías	Verde azulado #08A08C y violeta #8064B5	Distinguibles entre sí y del par principal.
Contexto	Azul grisáceo #A9BDD3	Acompaña sin competir por la atención.
Sin peso analítico	Grises #9AA5B1 y #D5DAE1	«Otros» y «Desconocido» no deben destacar.
Lienzo	#F4F6F8 con tarjetas blancas	Evita el blanco puro en pantalla grande.
Texto	Tinta #1F2A37	Contraste de 14,5:1 sobre blanco.

Validación de la paleta

La paleta se comprobó con un validador que simula daltonismo y mide contraste; no se eligió a ojo. El primer intento falló: el verde azulado estaba apagado y el naranja tenía poco contraste. Se ajustó y volvió a medirse.

Paleta	Resultado	Detalle
Categórica del dashboard	Aprobada	Peor separación con daltonismo ΔE 12,5; visión normal ΔE 21,6; contraste de al menos 3:1
Presentación pastel	Aprobada con aviso	ΔE 8,7 con daltonismo; naranja y menta bajo 3:1, compensado con etiquetas visibles
Tintes de Mezcla de formatos	No aprobados	Fallan el piso de croma y la separación normal (ΔE 14,5); se distinguen por leyenda y posición

Excepción declarada: los tintes de la mezcla se suavizaron para que los bloques grandes no cansen. Es una decisión estética con costo conocido, no una paleta validada.

Sección 11

Justificación de cada gráfico

Cada gráfico se eligió por el **tipo de pregunta estadística**, según el selector de Andrew Abela: comparación, composición, distribución y relación.

Gráfico	Pregunta	Tipo (Abela)	Por qué este gráfico
Tarjetas KPI	¿Cuál es la magnitud?	Valor único	Un número clave no necesita eje.
Área por año y formato	¿Cómo creció y cambió la mezcla?	Composición en el tiempo	Muestra total y capas en muchos períodos.
Líneas digital vs. óptico	¿Cuándo cambió el liderazgo?	Comparación en el tiempo	Dos líneas en un eje marcan el cruce.
Barras horizontales	¿Quién produce más?	Comparación	La longitud se compara bien y caben nombres largos.
Histograma	¿Cuánto dura una pista?	Distribución	Barras contiguas para clases continuas.
Columnas al 100 %	¿Qué dominó cada década?	Composición relativa	Compara proporciones aunque cambie el volumen.
Dispersión logarítmica	¿Más volumen implica más digital?	Relación	Cada punto es un país y revela casos atípicos.
Tabla Top 20	¿Qué valores exactos tienen?	Consulta	Da precisión en varias métricas.
Columnas por década, año y mes	¿Cómo se reparte en el tiempo?	Comparación temporal	Muestran cada nivel; el drill-down está en la tabla dinámica.
Tablas dinámicas de drill-down	¿Qué hay dentro de cada nivel?	Consulta jerárquica	Permiten bajar y subir de nivel sin salir de la página.
Top 15 áreas	¿Qué áreas concentran la producción?	Comparación	Compara las áreas principales de un vistazo.
Barras agrupadas por empaque	¿Qué empaque es más denso?	Comparación de dos medidas	Ambas medidas comparten unidad; evita el doble eje.
Mapa de calor ISRC	¿Qué países y tipos formalizan más?	Magnitud en cuadrícula	Un solo tono de claro a oscuro.
Tabla de emergentes	¿Quiénes son los nuevos artistas?	Consulta	Lista exacta con inicio desde 2015.

Gráficos descartados

- **Torta:** el ojo compara mal ángulos; con varios formatos, el 100 % apilado es más preciso.
- **Doble eje:** dos escalas sugieren correlaciones que dependen de cómo se elige cada una.
- **Mapa coroplético:** un país dominante satura la escala y el área geográfica distorsiona la lectura.
- **Dispersión con 30 colores:** la primera versión usaba un color por país. Se redujo a dos tonos porque tantos colores no comunicaban nada.

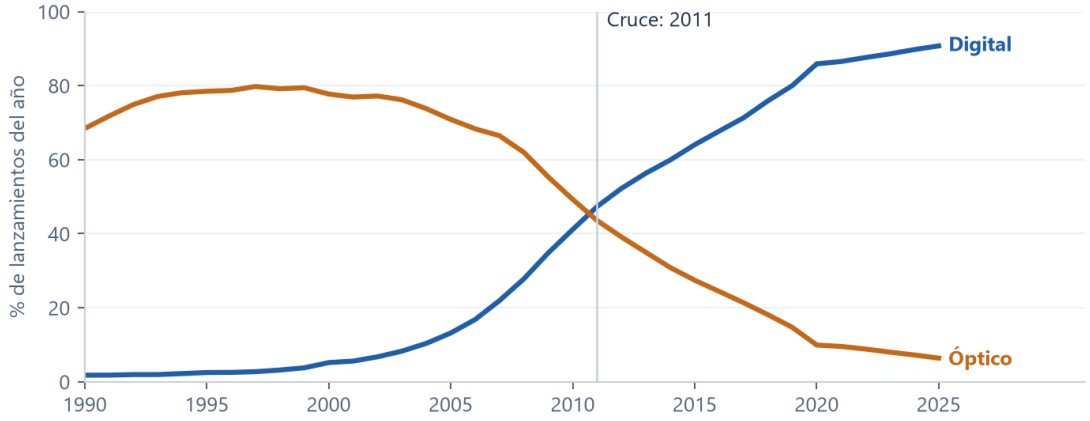


Figura 5. Cuota anual de digital y óptico. El cruce ocurre en 2011.

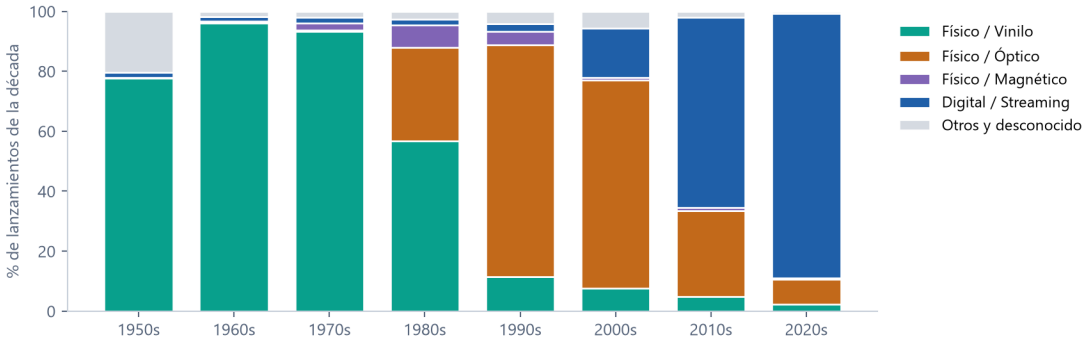


Figura 6. Mezcla de formatos por década, porcentaje de lanzamientos.

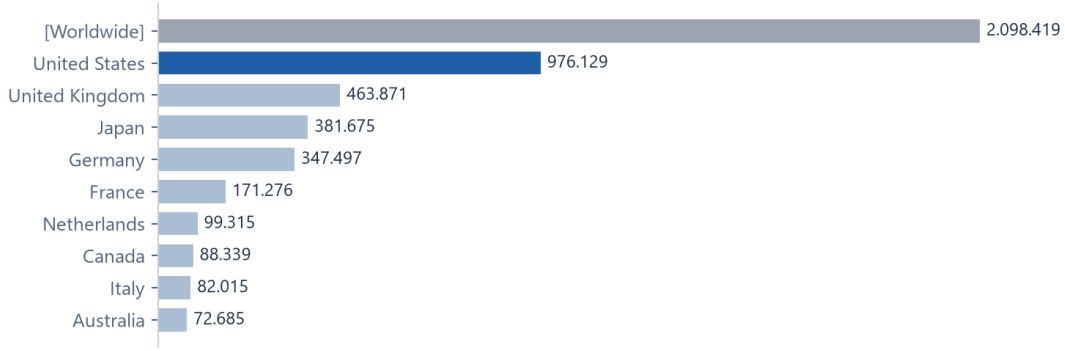


Figura 7. Lanzamientos por área: [Worldwide] y los nueve primeros países.

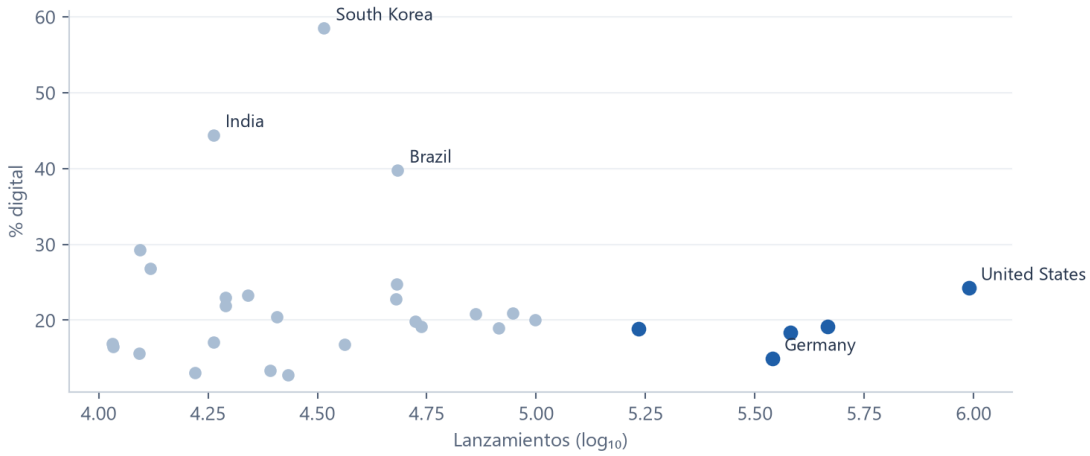


Figura 8. Volumen y digitalización en el Top 30 de países, con escala logarítmica.

Fundamentos estadísticos

Estadística	Medida	Por qué se usa
Total	SUM(lanzamientos)	Magnitud aditiva, válida con cualquier filtro.
Conteo distinto	COUNT(DISTINCT artista_key)	Artistas únicos: no se suman, se cuentan en el contexto filtrado.
Proporción	parte / NULLIF(total, 0)	Coberturas y participaciones.
Media ponderada	Σ segundos / Σ pistas con duración	Evita el promedio de promedios.
Moda y mediana	Banda más frecuente y percentil 50	Tendencia central robusta.
Correlación de Pearson	corr(año, duración media)	Fuerza y signo de una relación lineal.
Pendiente	regr_slope(duración, año)	Traduce r a segundos por año.
Escala logarítmica	LOG10(lanzamientos)	Top 30: de 10.736 a 976.129.

Distribución de la duración

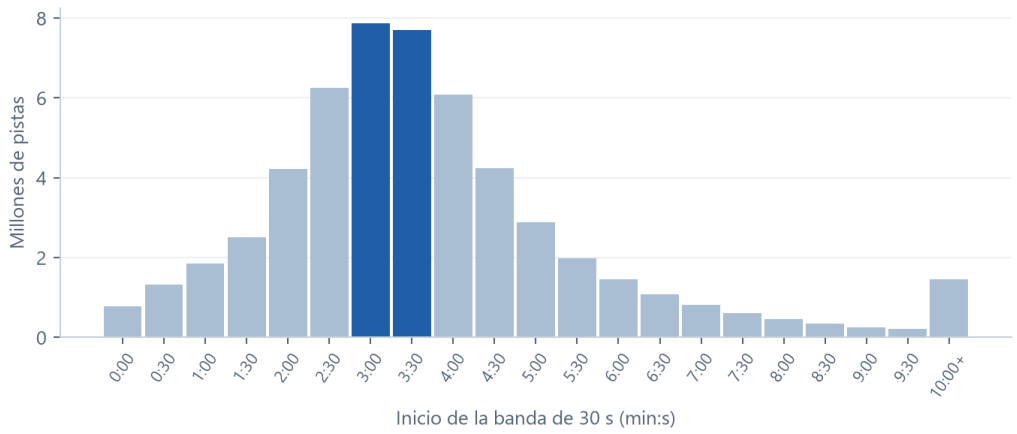


Figura 9. Pistas por banda de duración de 30 s (excluye pistas sin duración).

- **Moda:** 3:00–3:30 (14,4 %). **Mediana:** banda 3:30–4:00. **Media:** 4:14 min.
- **Concentración:** las dos bandas más frecuentes reúnen 28,6 % de las pistas. No son mayoría: esa cifra describe concentración, no un rango universal.
- **Asimetría positiva:** la media supera a la mediana por la cola larga; 2,7 % supera los 10 minutos.

Correlación año-duración (RF05)

Período	r de Pearson	Pendiente	Años (n)	Lectura
1950–2025	+0,917	+1,08 s/año	76	Fuerte y positiva, significativa al 5 %
1990–2025	+0,858	+0,66 s/año	36	Fuerte y positiva, significativa al 5 %
2013–2025	−0,343	−0,31 s/año	13	Negativa, no significativa al 5 %

Lectura honesta del resultado

La hipótesis de RF05 («el streaming acortó las canciones») **no queda demostrada**. A largo plazo la relación es positiva. En el período reciente r = −0,343 con n = 13: no alcanza el valor crítico de 0,553 para significancia al 5 %. Con la carga recortada se había reportado −0,57, un resultado más fuerte de lo que los datos completos sostienen. Además, el cálculo usa medias anuales y no prueba causalidad.

Sección 13

Trazabilidad de requisitos

Requisito	Dónde se responde	Estado
RF01 · Ranking Top N	Top 20 artistas y Top 10 países, con filtros	Cubierto; Top N fijo
RF02 · Formato e idioma	KPI de duración, Top idiomas y mezcla de formatos	Cubierto
RF03 · Drill-down	Tablas dinámicas de siglo a mes y de país a área, más clic en barras	Cubierto hasta mes; sin día
RF04 · Digital vs. físico	Líneas de cuota, área y KPI de pistas largas	Cubierto
RF05 · Correlación	Sección 12 de este documento; histograma en el dashboard	Cubierto en documento
RF06 · Formalización ISRC	Mapa de calor por país y tipo de artista	Cubierto
RF07 · Densidad	KPI y barras por empaque (Top 8)	Cubierto
RF08 · Emergentes	KPI de 47.764 artistas y Top 15 con 100 % ISRC (5.984 califican)	Cubierto

Sección 14

Limitaciones y trabajo futuro

- **Asignación a la primera pista:** un lanzamiento con varios artistas o formatos se atribuye a los de su primera pista.
- **Territorio:** la regla de 10 países es un criterio del proyecto; con 2 a 9 países se elige el de mayor catálogo, no necesariamente el origen real.
- **País de respaldo:** un lanzamiento sin país toma el área del artista de cada pista.
- **Fechas:** las anteriores a 1900 van a «sin fecha» y hay fechas futuras en el dato.
- **Top de artistas:** está dominado por compositores clásicos por las muchas reediciones; no mide popularidad.
- **Sin medir:** beneficio del clustering, concurrencia del warehouse y consumo de cuota.
- **Power BI:** el reporte queda como entrega anterior, con la carga de 15 M. El dashboard vigente es AI/BI.
- **Drill-down:** llega a mes, no a día. En geografía casi todos los países bajan a un solo nivel, porque el modelo no enlaza ciudades con su país.
- **Trabajo futuro:** completar la jerarquía geográfica y medir rendimiento comparado.

Sección 15

Preguntas probables del profesor

P: ¿Por qué una estrella y no un copo de nieve?

R: Minimiza joins, es fácil de entender y funciona bien con herramientas de BI. Las jerarquías se desnormalizan dentro de cada dimensión.

P: ¿Cuál es el grano?

R: Una fila por pista en fact_pista. Los agregados consolidan por día y dimensiones para dar rapidez al dashboard.

P: ¿Son aditivas todas las métricas?

R: Sí. Cada lanzamiento, soporte y grabación suma una sola vez. La suma coincide con el conteo distinto: 5.890.921 lanzamientos. Los artistas activos se calculan como conteo distinto, no se suman.

P: ¿Qué es la clave 0?

R: El miembro desconocido de cada dimensión: los totales cuadran y se ve cuánto dato falta.

P: ¿Por qué 29,1 % de ISRC?

R: Es la cobertura en MusicBrainz. Indica cuántas pistas registradas allí tienen código, no el registro real en la industria.

P: ¿Por qué [Worldwide] es tan grande?

R: Es el territorio de lanzamientos multiterritoriales. Se compara aparte porque no es un país.

P: ¿La correlación prueba que el streaming acortó las canciones?

R: No. Entre 2013 y 2025, r = −0,343 no es significativa y Pearson no prueba causalidad.

P: ¿Cómo sabe que los números son correctos?

R: Por 116 reglas bloqueantes, pruebas con datos pequeños, conciliación con el volcado y filtros comparados con SQL. Aun así, dos errores se hallaron por inspección, por eso también revisamos resultados.

P: ¿Por qué no usó una paleta validada en todos los gráficos?

R: La mezcla usa tintes suaves por comodidad visual. Se declara la excepción: se distinguen por leyenda y posición.

Sección 16

Guion para la mesa directiva

Duración estimada: **8 minutos**. Las frases en cursiva son para decir; los corchetes indican acciones en pantalla. Conviene abrir cada página unos minutos antes.

0:00 – 0:45 · Apertura
[Resumen ejecutivo, sin filtros]

«Buenos días. Les voy a mostrar qué dicen casi 59 millones de pistas sobre la producción musical. Todo sale de un Data Warehouse verificado sobre el catálogo público de MusicBrainz.»

0:45 – 1:45 · Tamaño del catálogo
[Señalar las tarjetas KPI]

«Son 5.890.921 lanzamientos y 1.633.826 artistas activos. El 29,1 % de las pistas tiene código ISRC en este catálogo, y esa es la métrica de formalización que seguiremos.»

1:45 – 3:00 · La gran transición
[Señalar área y líneas]

«En 2011 digital superó a los formatos ópticos. En 2025 digital ya es 90,7 % de los lanzamientos con fecha. La distribución digital ya no es un canal alternativo.»

3:00 – 4:00 · Dónde se produce
[Señalar Top 10 países]

«Estados Unidos, Reino Unido y Japón encabezan los países. Hay además 2.098.419 lanzamientos multiterritoriales, una señal de que mucho contenido se publica globalmente desde el primer día.»

4:00 – 5:00 · Qué caracteriza a la música
[Análisis detallado, histograma]

«La duración más frecuente está entre 3:00–3:30. Sobre si el streaming acortó las canciones: la caída reciente es débil y no permite afirmarlo.»

5:00 – 6:00 · Volumen y digitalización
[Señalar la dispersión]

«Más volumen no significa más digital. Corea del Sur llega a 58,5 %: los mercados pequeños y muy digitales merecen una mirada aparte.»

6:00 – 7:00 · Calidad y talento
[Calidad y catálogo]

«El mapa de calor muestra dónde está más formalizado el catálogo. 5.984 artistas emergentes ya tienen todas sus pistas con ISRC.»

7:00 – 8:00 · Confianza y cierre
[Volver al Resumen ejecutivo]

«Encontramos y corregimos errores reales antes de esta reunión, y cada cifra se concilia con la fuente. Recomendamos priorizar digital, impulsar el registro ISRC y observar mercados muy digitales. ¿Preguntas?»

Anexo A

Medidas del dashboard en SQL

Expresiones reales de las tarjetas KPI, extraídas del archivo del dashboard. Se usan NULLIF para evitar divisiones por cero y sumas ponderadas para evitar el promedio de promedios.

Página	KPI	Expresión	Dataset
Resumen ejecutivo	Lanzamientos	`SUM(lanzamientos)`	ds_resumen
Resumen ejecutivo	Pistas	`SUM(pistas)`	ds_resumen
Resumen ejecutivo	Artistas activos	`COUNT(DISTINCT artista_key)`	ds_resumen_artistas
Resumen ejecutivo	Cobertura ISRC	`SUM(pistas_isrc) / NULLIF(SUM(pistas), 0)`	ds_resumen
Resumen ejecutivo	Participación digital	`SUM(lanzamientos_digitales) / NULLIF(SUM(lanzamientos), 0)`	ds_resumen
Análisis detallado	Pistas por lanzamiento	`SUM(pistas) / NULLIF(SUM(lanzamientos), 0)`	ds_detallado
Análisis detallado	Duración promedio por pista (min)	`SUM(duracion_segundos) / NULLIF(SUM(pistas_completas), 0) / 60`	ds_detallado
Análisis detallado	Pistas de más de 5 minutos	`SUM(pistas_largas) / NULLIF(SUM(pistas), 0)`	ds_detallado
Análisis detallado	Horas totales de audio	`SUM(duracion_minutos) / 60`	ds_detallado
Calidad y catálogo	Cobertura ISRC	`SUM(pistas_isrc) / NULLIF(SUM(pistas), 0)`	ds_calidad
Calidad y catálogo	Pistas por lanzamiento	`SUM(pistas) / NULLIF(SUM(lanzamientos), 0)`	ds_calidad
Calidad y catálogo	Pistas por soporte	`SUM(pistas) / NULLIF(SUM(soportes), 0)`	ds_calidad
Calidad y catálogo	Artistas emergentes (inicio desde 2015)	`COUNT(DISTINCT artista_key)`	ds_emergentes

Anexo B

Glosario

Término	Significado
Grano	Lo que representa exactamente una fila de un hecho.
Lanzamiento (release)	Publicación concreta de un álbum, sencillo o EP.
Soporte (medium)	Disco o medio dentro de un lanzamiento.
Grabación (recording)	La obra grabada; puede aparecer en varios lanzamientos.
Pista (track)	Aparición de una grabación en un soporte.
ISRC	Código internacional que identifica una grabación.
Delta Lake	Formato de tabla con transacciones e historial sobre archivos Parquet.
Time travel	Consultar una versión anterior de una tabla Delta.
Liquid clustering	Organización de datos que reemplaza particiones y ZORDER.
AI/BI	Herramienta de dashboards de Databricks.