PROYECTO INTEGRADOR | BASES DE DATOS AVANZADAS

Data Warehouse Masivo de la Industria Musical Global (DWMusicBrainz)

PostgreSQL 16 en Docker | Arquitectura Medallón (Silver → Gold)
Modelo en Estrella Puro en Español (Ralph Kimball Star Schema)
100% Datos Reales MusicBrainz (~89.3M Filas Silver, Hechos Históricos Diarios Aditivos) | Power BI

DOCUMENTO OFICIAL DE SUSTENTACIÓN TÉCNICA Y GUÍA DE DEFENSA

Este documento técnico consolida la arquitectura analítica, el modelo dimensional en estrella puro en español, la estructura exacta de las 6 dimensiones conformadas y la tabla de hechos histórica diaria (gold.fact_produccion_musical) diseñada exclusivamente con claves foráneas y 11 métricas numéricas 100% aditivas (cero textos y cero booleanos). Alimentado con el volcado oficial de la **MetaBrainz Foundation (Schema Sequence 31)**, incorpora las fechas reales de publicación (release_country) y créditos autorales (artist_credit_name), superando los **14.5 GB** en disco y garantizando **cero huérfanos**.

Programa: Ingeniería de Sistemas	**Asignatura:** Bases de Datos Avanzadas
Semestre: 5to Semestre Académico	**Institución:** Universidad Popular del Cesar
Integrantes: Juan Sebastián Rincón Farelo y equipo	**Docente:** Docente Titular de la Cátedra
Fecha: Octubre de 2026	**Ubicación:** Valledupar, Cesar, Colombia

ÍNDICE GENERAL DE CONTENIDO

Estructura capitular del documento de sustentación técnica

Capítulo	Título del Capítulo y Alcance Temático	Pág.
1	**Resumen ejecutivo y contexto:** Problema OLTP, solución OLAP de grano histórico diario y arquitectura general.	3
2	**Objetivos y requerimientos:** Matriz de requerimientos funcionales RF01–RF08 y no funcionales RNF01–RNF09.	4
3	**Volumetría y dimensionamiento físico:** Las 10 tablas Silver (~89.3M filas) y el Modelo Estrella Gold en español.	6
4	**La base de datos de origen:** MusicBrainz Sequence 31, resolución de fechas reales y créditos de artistas.	7
5	**Diseño del Modelo en Estrella Puro en Español:** Grano histórico diario, atributos exactos de dimensiones y hechos.	8
6	**Arquitectura Medallón y Stack Tecnológico:** Capas Silver, Gold y Meta; justificación de herramientas elegidas.	11
7	**Reglas del proceso EDA:** Catálogo E01–E10, eliminación de booleanos en hechos y fechas reales.	13
8	**Proceso ETL de alto rendimiento:** Extracción bajo demanda, MaxLineReader y agregación histórica set-based.	14
9	**Capa Oro: agregaciones, índices y particiones:** 14 particiones por fecha_key, índices B-tree y 4 vistas materializadas.	16
10	**Dashboard Power BI y Storytelling:** Medidas DAX 100% aditivas (SUM) y hallazgos de negocio.	17
11	**Guía por diapositiva para la defensa oral:** Resumen técnico y discurso de defensa para 13 diapositivas.	19
12	**Banco de preguntas técnicas para la sustentación:** 15 preguntas de rigor con respuestas de Senior Architect.	22
13	**Puntos de atención y lista de verificación:** Checklist previo a la evaluación y certificación final.	24

Corrección Arquitectónica Clave Implementada: La tabla de hechos central (gold.fact_produccion_musical) fue rediseñada como un verdadero **almacenamiento histórico diario** donde cada registro consolida la producción musical por día (fecha_key) y dimensiones conformadas, almacenando **únicamente claves foráneas y métricas numéricas 100% aditivas** (cero booleanos y cero textos).

CAPÍTULO 1

Resumen ejecutivo y contexto

Qué problema se resuelve, cómo se modela el almacenamiento histórico diario y arquitectura general

1.1. Contexto de Negocio: Del Catálogo Operacional al Almacenamiento Histórico

En la industria musical global, bases de datos transaccionales (OLTP) como MusicBrainz normalizan el catálogo en decenas de tablas en **Tercera Forma Normal (3NF)**: track, recording, medium, release, release_country, artist_credit_name, artist, area e isrc. Un error frecuente al construir un Data Warehouse es volcar las pistas individuales con sus nombres y booleanos a una tabla llamada 'fact', creando un catálogo desnormalizado en lugar de una verdadera tabla de hechos histórica.

1.2. La Solución Arquitectónica: DWMusicBrainz (Estrella Pura en Español)

El proyecto **DWMusicBrainz** implementa en **PostgreSQL 16 (Docker, puerto 5435)** una **Arquitectura Medallón (Silver → Gold)** donde la capa Gold está modelada íntegramente en español bajo las reglas estrictas de **Ralph Kimball**:

- **Grano Histórico Diario + Dimensional:** Cada registro en gold.fact_produccion_musical consolida la actividad histórica de un día (fecha_key) cruzada con las 5 dimensiones de contexto (artista_key, lanzamiento_key, geografia_key, formato_key, idioma_key).
- **Métricas 100% Aditivas (Cero Textos, Cero Booleanos):** La tabla de hechos contiene exclusivamente FKs enteras y 11 métricas cuantitativas aditivas: lanzamientos_total, soportes_total, pistas_total, grabaciones_unicas_total, duraciones acumuladas y conteos aditivos de ISRC, pistas largas, videos y pistas completas.
- **Verdad Histórica desde el Dump Oficial:** Se extraen de mbdump.tar.bz2 (7.1 GB, Sequence 31) las tablas release_country y release_unknown_country para obtener las fechas reales de lanzamiento (1900–2026) y artist_credit_name para resolver el artista principal exacto.

1.3. Matriz Resumen de Hitos y Entregables del Proyecto

Hito	Fase Arquitectónica	Alcance Técnico Verificado	Estado
H0	Fase 0: Infraestructura	Docker Compose (PG16 en 5435), tuning 1GB buffers y shm_size=1gb, esquemas meta/silver/gold.	100% OK
H1	Fase 1: Ingesta Silver (10 Tablas)	Extracción quirúrgica y COPY de ~89.3M filas (incluyendo release_country y artist_credit_name).	100% OK
H2	Fase 2: Dimensiones Gold (Español)	Poblado de 6 dimensiones conformadas en español con Surrogate Keys y Patrón Fila Cero (Key 0).	100% OK
H3	Fase 3: Hechos Históricos y MVs	Consolidación diaria en fact_produccion_musical (11 métricas aditivas) y 4 vistas materializadas.	100% OK
H4	Fase 4: Auditoría y Power BI	Registro en meta.data_quality_log (0 huérfanos) y medidas DAX basadas 100% en SUM.	100% OK

CAPÍTULO 2

Objetivos y matriz de requerimientos

Objetivo general, objetivos específicos y catálogo formal RF01–RF08 y RNF01–RNF09

2.1. Objetivo General

Diseñar, implementar y desplegar un Data Warehouse analítico de alta volumetría empresarial utilizando datos 100% reales de MusicBrainz (MetaBrainz Foundation, Schema Sequence 31), estructurado bajo una Arquitectura Medallón (Silver → Gold) y un Modelo en Estrella Puro en español (Ralph Kimball) cuya tabla de hechos (gold.fact_produccion_musical) consolide el registro histórico diario mediante claves foráneas conformadas y métricas numéricas 100% aditivas.

2.2. Objetivos Específicos

• **OE1:** Ingestar en la capa silver las 10 tablas relacionales clave de MusicBrainz (~89.3 millones de filas totales), incluyendo fechas históricas reales y créditos de artistas.

• **OE2:** Modelar en la capa gold 6 dimensiones conformadas en español con claves subrogadas y el patrón de Fila Cero (Key 0) garantizando cero huérfanos.

• **OE3:** Consolidar la tabla de hechos histórica gold.fact_produccion_musical por día y dimensiones, libre de atributos textuales y booleanos, con particionamiento físico por rangos en fecha_key.

• **OE4:** Construir 4 vistas materializadas analíticas indexadas en español para responder consultas OLAP y tableros de Power BI en menos de 0.1 segundos.

2.3. Matriz de Requerimientos Funcionales (RF01 — RF08)

Req.	Nombre y Descripción Funcional	Tablas Gold Involucradas	Métrica Aditiva / Operación
RF01	**Ranking Top N de Artistas y Producción:** Volumen de lanzamientos, pistas, duración acumulada y cobertura ISRC por país y década.	fact_produccion_musical, dim_artista, dim_fecha	SUM(lanzamientos_total), SUM(pistas_total)
RF02	**Métricas por Formato e Idioma:** Duración promedio ponderada y volumen según formato (Vinilo, CD, Digital) e idioma.	fact_produccion_musical, dim_formato, dim_idioma	SUM(duracion_total_segundos) / SUM(pistas_completas_total)
RF03	**Drill-Down Geográfico y Temporal:** Navegación País > Tipo de Área y Siglo > Década > Año > Mes > Día.	fact_produccion_musical, dim_geografia, dim_fecha	SUM(lanzamientos_total), SUM(duracion_total_minutos)
RF04	**Comparativa Físico vs Digital y Canciones Largas:** Volumen de pistas largas (>300s) frente al total por categoría de soporte.	fact_produccion_musical, dim_formato	SUM(pistas_largas_total) / SUM(pistas_total)
RF05	**Correlación Estadística Streaming vs Vinilo:** Demostración matemática del acortamiento musical por año histórico.	fact_produccion_musical, dim_fecha	corr(anio, duracion_promedio_seg)
RF06	**Formalización Discográfica (ISRC):** Tasa de pistas con código internacional ISRC según país y tipo de artista.	fact_produccion_musical, dim_geografia, dim_artista	SUM(pistas_con_isrc_total) * 100.0 / SUM(pistas_total)
RF07	**Densidad de Pistas y Soportes por Lanzamiento:** Promedio de pistas por álbum y por soporte físico/digital.	fact_produccion_musical, dim_lanzamiento, dim_formato	SUM(pistas_total) / SUM(lanzamientos_total)
RF08	**Catálogo Emergente y Nuevos Talentos:** Artistas debutantes en la última década con mayor volumen y cobertura ISRC.	fact_produccion_musical, dim_artista, dim_fecha	anio_inicio >= 2015, SUM(pistas_con_isrc_total)

2.4. Matriz de Requerimientos No Funcionales (RNF01 — RNF09)

RNF	Criterio / Dimensión	Meta Exigida	Implementación en DWMusicBrainz	Estado
RNF01	Procesamiento por Chunks	Streaming sin saturar RAM	MaxLineReader con buffer de 128 KB en Python	100% OK
RNF02	Almacenamiento en Disco	> 3.0 GB físico en PostgreSQL	**> 14.5 GB reales** entre Silver (10 tablas) y Gold	SUPERADO
RNF03	Volumetría Real Procesada	> 10.000.000 registros base	**~89.3M filas en Silver** y 15M pistas consolidadas en hechos	SUPERADO
RNF04	Garantía Cero Sintéticos	100% datos reales auditables	Volcado oficial MusicBrainz Sequence 31 (mbdump.tar.bz2)	100% OK
RNF05	Idempotencia del Pipeline	Re-ejecuciones sin duplicados	TRUNCATE RESTART IDENTITY y ON CONFLICT DO UPDATE	100% OK
RNF06	Auditoría y Calidad	Trazabilidad E2E y reglas DQ	meta.etl_audit + meta.data_quality_log automatizados	100% OK
RNF07	SLA de Consulta Analítica	< 3.00 s en consultas OLAP	< 0.10 s gracias a métricas pre-sumadas y MVs	ÓPTIMO
RNF08	Integridad Referencial	0 registros huérfanos	Patrón Key 0 en las 6 dimensiones en español	100% OK
RNF09	Despliegue Reproducible	Contenerización total	Docker Compose con postgres:16 y shm_size 1GB	100% OK

CAPÍTULO 3

Volumetría y dimensionamiento físico

Las 10 tablas de la capa Silver y el Modelo en Estrella Puro de la capa Gold

3.1. Consolidado de Tablas por Capa (Silver 3NF y Gold Estrella)

Esquema	Tabla / Objeto	Filas Reales / Est.	Grano y Rol en el Data Warehouse	Disco Est.
silver	**recording**	40.532.448	Grabación maestra de estudio (duración master y flag video)	4.998 MB
silver	**track**	15.000.000	Pista musical en un soporte (base atómica de conteo)	1.967 MB
silver	**isrc**	6.478.709	Códigos internacionales ISRC por grabación	795 MB
silver	**medium**	6.411.799	Soporte físico o digital que compone un lanzamiento	986 MB
silver	**artist_credit_name**	~6.210.000	Vínculo exacto entre artist_credit y artist.id (position=0)	420 MB
silver	**release**	5.844.569	Lanzamiento discográfico (estado, empaque, idioma, calidad)	1.108 MB
silver	**release_country**	~5.480.000	Fecha histórica real (año/mes/día) y país de lanzamiento	385 MB
silver	**artist**	3.010.451	Catálogo de músicos solistas, grupos, coros y orquestas	498 MB
silver	**release_unknown_country**	~215.000	Fecha histórica real de publicación sin país asignado	18 MB
silver	**area**	120.107	Países, regiones, subdivisiones y ciudades	14 MB
gold	**fact_produccion_musical**	~4.5M – 5.8M	Hecho histórico diario (consolida las 15M de pistas en SUMs)	~2.450 MB
gold	**dim_artista**	3.010.452	Dimensión conformada de artistas con área y país	758 MB
gold	**dim_geografia**	120.108	Dimensión conformada geográfica (país y tipo de área)	15 MB
gold	**dim_fecha**	47.848	Calendario diario continuo (1900 a 2030) + Clave 0	4 MB
gold	**dim_idioma / formato / lanz.**	~620	Dimensiones conformadas de idioma (354), perfil lanz. (~150) y formato (114)	< 3 MB

CAPÍTULO 4

La base de datos de origen: MusicBrainz Sequence 31

Extracción quirúrgica desde mbdump.tar.bz2, fechas reales y resolución de créditos

4.1. Por qué incluimos release_country, release_unknown_country y artist_credit_name

Al analizar el esquema relacional nativo de MusicBrainz (Schema Sequence 31), detectamos dos particularidades críticas que todo arquitecto de datos debe resolver al construir el Data Warehouse:

1. **La fecha real de lanzamiento NO vive en la tabla release:** En silver.release solo existe la columna last_updated (cuándo un editor modificó la fila). Las fechas históricas reales de publicación (año, mes y día en que salió el disco a la venta, junto con el país del evento) residen en release_country (275 MB) y release_unknown_country (8.4 MB). Al incorporarlas en Silver, nuestra dimensión gold.dim_fecha refleja la historia real de la música desde 1900 hasta 2026.

2. **El campo artist_credit NO es artist.id:** En MusicBrainz, tanto release como track apuntan a un identificador de crédito artístico (artist_credit) que puede agrupar colaboraciones. La tabla puente silver.artist_credit_name (232 MB) permite resolver con exactitud el artista principal (position = 0) hacia silver.artist.id.

4.2. Contraste Crítico: Tabla de Catálogo Desnormalizada vs Tabla de Hechos de Kimball

Aspecto de Diseño	Planteamiento Erróneo (Catálogo Desnormalizado)	Diseño Correcto Implementado (Hechos de Kimball)
Grano de la Tabla	1 fila por canción individual con su título de texto y UUID.	1 registro histórico por Día (fecha_key) y combinación de las 5 dimensiones.
Columnas en la Tabla de Hechos	Mezcla FKs con strings (track_name, isrc_code) y booleanos (has_isrc, is_video).	**Exclusivamente Claves Foráneas (FKs) y 11 Métricas Numéricas Aditivas.**
Comportamiento de lanzamientos_total	Si dim_release tiene 5.8M de álbumes individuales, cada fila vale siempre 1.	Con dim_lanzamiento por perfil conformado, lanzamientos_total suma los álbumes reales del día.
Operación Analítica en Power BI	Obliga a hacer COUNTROWS filtrando booleanos en 19M de filas.	Todas las métricas se calculan con **SUM() directo** a velocidad de memoria.

CAPÍTULO 5

Diseño del modelo en estrella puro en español (Ralph Kimball)

Declaración de grano histórico diario, atributos exactos de cada tabla y DDLs de producción

5.1. Declaración Oficial del Grano Histórico Diario

DECLARACIÓN OFICIAL DEL GRANO (KIMBALL GRAIN STATEMENT):
'Un registro individual en la tabla de hechos central (gold.fact_produccion_musical) representa el resumen histórico diario (fecha_key) de la producción musical consolidada por artista (artista_key), perfil de lanzamiento (lanzamiento_key), ubicación geográfica (geografia_key), formato de soporte (formato_key) e idioma (idioma_key), conteniendo exclusivamente claves foráneas conformadas y métricas numéricas 100% aditivas.'

5.2. Visualización Exacta de Atributos del Modelo en Estrella (Capa Gold)

A continuación se detallan exactamente todas las tablas y columnas que conforman el esquema gold en PostgreSQL 16 (sql/gold/03_dimensions_facts.sql):

Tabla en Esquema Gold	Clave Primaria (PK)	Listado Exacto de Columnas / Atributos	Rol y Naturaleza
gold.fact_produccion_musical	PK Compuesta: (hecho_key, fecha_key)	**FKs:** fecha_key, artista_key, lanzamiento_key, geografia_key, formato_key, idioma_key. **Métricas Aditivas (11):** lanzamientos_total, soportes_total, pistas_total, grabaciones_unicas_total, duracion_total_ms, duracion_total_segundos, duracion_total_minutos, pistas_con_isrc_total, pistas_largas_total, pistas_video_total, pistas_completas_total.	Tabla de Hechos Histórica Diaria Particionada. Cero textos, cero booleanos.
gold.dim_fecha	fecha_key (INTEGER YYYYMMDD)	fecha_key, fecha_completa, anio, trimestre, nombre_trimestre, mes, nombre_mes, nombre_mes_corto, dia, dia_semana, nombre_dia, es_fin_de_semana, decada, siglo.	Dimensión Calendario (1900–2030, 47.848 filas + Key 0).
gold.dim_artista	artista_key (SERIAL)	artista_key, artista_id (UK), artista_gid, nombre_artista, nombre_orden, tipo_artista, genero, area_id, nombre_area, nombre_pais, anio_inicio, anio_fin, finalizado, creado_en.	Dimensión Artistas (3.010.452 filas + Key 0).
gold.dim_lanzamiento	lanzamiento_key (SERIAL)	lanzamiento_key, estado_id, empaque_id, calidad_id, estado_lanzamiento, tipo_empaque, calidad_datos, creado_en.	Dimensión Perfil de Lanzamiento (~150 combinaciones + Key 0).
gold.dim_geografia	geografia_key (SERIAL)	geografia_key, area_id (UK), area_gid, nombre_area, tipo_area, nombre_pais, creado_en.	Dimensión Geográfica (120.108 áreas + Key 0).
gold.dim_formato	formato_key (SERIAL)	formato_key, formato_id (UK), nombre_formato, categoria_formato.	Dimensión Formatos Físicos/Digitales (114 filas + Key 0).
gold.dim_idioma	idioma_key (SERIAL)	idioma_key, idioma_id (UK), nombre_idioma, codigo_iso.	Dimensión Idiomas ISO 639-3 (354 filas + Key 0).

5.3. DDL Oficial de Producción: gold.fact_produccion_musical

```
CREATE TABLE IF NOT EXISTS gold.fact_produccion_musical (
    hecho_key                   BIGSERIAL,
    -- 1. Claves Foráneas Conformadas (Grano Histórico Diario + Dimensional)
    fecha_key                   INTEGER NOT NULL, -- FK -> gold.dim_fecha
    artista_key                 INTEGER NOT NULL, -- FK -> gold.dim_artista
    lanzamiento_key             INTEGER NOT NULL, -- FK -> gold.dim_lanzamiento
    geografia_key               INTEGER NOT NULL, -- FK -> gold.dim_geografia
    formato_key                 INTEGER NOT NULL, -- FK -> gold.dim_formato
    idioma_key                  INTEGER NOT NULL, -- FK -> gold.dim_idioma
    -- 2. Métricas Numéricas 100% Aditivas (Cero textos, cero booleanos)
    lanzamientos_total          INTEGER NOT NULL DEFAULT 0,
    soportes_total              INTEGER NOT NULL DEFAULT 0,
    pistas_total                INTEGER NOT NULL DEFAULT 0,
    grabaciones_unicas_total    INTEGER NOT NULL DEFAULT 0,
    duracion_total_ms           BIGINT  NOT NULL DEFAULT 0,
    duracion_total_segundos     NUMERIC(14, 2) NOT NULL DEFAULT 0.00,
    duracion_total_minutos      NUMERIC(14, 2) NOT NULL DEFAULT 0.00,
    pistas_con_isrc_total       INTEGER NOT NULL DEFAULT 0,
    pistas_largas_total         INTEGER NOT NULL DEFAULT 0,
    pistas_video_total          INTEGER NOT NULL DEFAULT 0,
    pistas_completas_total      INTEGER NOT NULL DEFAULT 0,
    PRIMARY KEY (hecho_key, fecha_key)
) PARTITION BY RANGE (fecha_key);
```

5.4. DDL Oficial: Particionamiento Físico por Rango en fecha_key

```
CREATE TABLE IF NOT EXISTS gold.fact_produccion_unknown   PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (0) TO (1900
0101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_pre_1970  PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (19000101) T
O (19700101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_1970s     PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (19700101) T
O (19800101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_1980s     PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (19800101) T
O (19900101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_1990s     PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (19900101) T
O (20000101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2000s     PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20000101) T
O (20100101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2010s     PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20100101) T
O (20200101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2020      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20200101) T
O (20210101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2021      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20210101) T
O (20220101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2022      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20220101) T
O (20230101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2023      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20230101) T
O (20240101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2024      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20240101) T
O (20250101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2025      PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20250101) T
O (20260101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_2026_plus PARTITION OF gold.fact_produccion_musical FOR VALUES FROM (20260101) T
O (20310101);
CREATE TABLE IF NOT EXISTS gold.fact_produccion_default   PARTITION OF gold.fact_produccion_musical DEFAULT;
```

CAPÍTULO 6

Arquitectura Medallón y justificación tecnológica

Roles por capa (Silver, Gold, Meta), herramientas utilizadas y decisiones de diseño

6.1. Definición de Capas en la Arquitectura Medallón

• **Capa Plata (Silver - 10 Tablas 3NF):** Conserva los nombres técnicos de MusicBrainz, aplica tipos fuertes y TEXT TOAST, e incorpora los eventos históricos de publicación (release_country, release_unknown_country) y créditos (artist_credit_name).

• **Capa Oro (Gold - Modelo Estrella en Español):** Traduce toda la capa de negocio al español (dim_fecha, dim_artista, dim_lanzamiento, dim_geografia, dim_formato, dim_idioma y fact_produccion_musical) con métricas pre-agregadas aditivas.

• **Capa Meta (Gobernanza):** Registra la auditoría de lotes en meta.etl_audit y los controles de calidad referencial en meta.data_quality_log.

6.2. Justificación Técnica del Stack de Herramientas Elegido

Herramienta	Versión / Rol	Justificación Arquitectónica
PostgreSQL	v16 (Docker) Motor DWH	Soporte nativo de Range Partitioning en fecha_key, COPY streaming de alta velocidad, Vistas Materializadas indexadas y paralelismo con shared_buffers=1GB.
Docker Compose	v2 / Puerto 5435 Infraestructura	Aislamiento total con shm_size=1gb para evitar fallos de Dynamic Shared Memory en agrupaciones masivas.
Python + psycopg2	v3.12+ Orquestador ETL	Extracción quirúrgica bajo demanda desde mbdump.tar.bz2 y streaming con MaxLineReader (buffer 128 KB) directo a libpq COPY.
Power BI Desktop	Consumo BI Motor VertiPaq	Aprovecha las relaciones 1:* del modelo en estrella en español y evalúa todas las medidas con SUM() sobre métricas aditivas.

CAPÍTULO 7

Reglas del proceso EDA y calidad de datos

Catálogo oficial E01 a E10 aplicado en la transformación Silver -> Gold

ID	Regla de Calidad	Acción Técnica Implementada	Impacto en el Modelo Estrella
E01	Duraciones nulas o en 0	GREATEST(COALESCE(NULLIF(t.length,0), NULLIF(rec.length,0), 0), 0).	Rescata la duración del recording master y suma en pistas_completas_total.
E02	Fechas reales de publicación	Prioridad: release_country -> release_unknown_country -> artist.begin_date_year -> 0.	Asigna la fecha histórica real (YYYYMMDD) en dim_fecha.
E03	Resolución de artist_credit	JOIN con silver.artist_credit_name (position = 0).	Vincula el lanzamiento y la pista con el artist_id principal real.
E04	Deduplicación de ISRC	Subconsulta SELECT DISTINCT recording FROM silver.isrc.	Evita duplicar filas por múltiples ISRCs y suma en pistas_con_isrc_total.
E05	Cero booleanos en Hechos	Conversión de flags a SUM(CASE WHEN ... THEN 1 ELSE 0 END).	Genera métricas enteras 100% aditivas (pistas_largas_total, pistas_video_total).
E06	Cadenas > 1.000 caracteres	Uso de tipo TEXT nativo con compresión TOAST en Silver y Gold.	Cero abortos por truncamiento en títulos extensos.
E07	Patrón Fila Cero (Key 0)	COALESCE(dim_key, 0) en las 6 claves foráneas del hecho.	Garantiza **CERO HUÉRFANOS** sin descartar actividad histórica.
E08	Saneamiento UTF-8 BOM	Lectura con encoding='utf-8-sig' y errors='replace'.	Compatibilidad total en entornos Windows.
E09	Cruce geográfico por ID	JOIN exacto por area_id entero hacia gold.dim_geografia.	Elimina el Fan Trap que ocurría al cruzar por nombres de ciudades homónimas.
E10	Auditoría en data_quality_log	Validación automatizada al cierre de run_gold_pipeline.py.	Deja evidencia persistente de 0 violaciones en meta.data_quality_log.

CAPÍTULO 8

Proceso ETL de alto rendimiento

Extracción quirúrgica bajo demanda y consulta SQL de agregación histórica diaria

8.1. SQL de Consolidación Histórica Diaria (etl/gold/populate_fact_tracks.sql)

La carga de gold.fact_produccion_musical resuelve fechas reales, artista principal, perfil de lanzamiento y agrupa (GROUP BY) por día y dimensiones conformadas:

```
INSERT INTO gold.fact_produccion_musical (
    fecha_key, artista_key, lanzamiento_key, geografia_key, formato_key, idioma_key,
    lanzamientos_total, soportes_total, pistas_total, grabaciones_unicas_total,
    duracion_total_ms, duracion_total_segundos, duracion_total_minutos,
    pistas_con_isrc_total, pistas_largas_total, pistas_video_total, pistas_completas_total
)
SELECT
    COALESCE(d.fecha_key, 0), COALESCE(da.artista_key, 0), COALESCE(dl.lanzamiento_key, 0),
    COALESCE(dg.geografia_key, 0), COALESCE(df.formato_key, 0), COALESCE(di.idioma_key, 0),
    COUNT(DISTINCT dp.release_id)::INTEGER AS lanzamientos_total,
    COUNT(DISTINCT dp.medium_id)::INTEGER  AS soportes_total,
    COUNT(dp.track_id)::INTEGER            AS pistas_total,
    COUNT(DISTINCT dp.recording_id)::INTEGER AS grabaciones_unicas_total,
    SUM(dp.duracion_ms)::BIGINT            AS duracion_total_ms,
    ROUND(SUM(dp.duracion_ms) / 1000.0, 2) AS duracion_total_segundos,
    ROUND(SUM(dp.duracion_ms) / 60000.0, 2) AS duracion_total_minutos,
    SUM(dp.tiene_isrc)::INTEGER            AS pistas_con_isrc_total,
    SUM(CASE WHEN dp.duracion_ms > 300000 THEN 1 ELSE 0 END)::INTEGER AS pistas_largas_total,
    SUM(dp.es_video)::INTEGER              AS pistas_video_total,
    SUM(CASE WHEN dp.duracion_ms > 0 THEN 1 ELSE 0 END)::INTEGER AS pistas_completas_total
FROM detalle_pistas dp
LEFT JOIN gold.dim_fecha d ON dp.fecha_candidata = d.fecha_key
LEFT JOIN gold.dim_artista da ON dp.artista_id_resuelto = da.artista_id
LEFT JOIN gold.dim_lanzamiento dl ON dp.estado_id = dl.estado_id
   AND dp.empaque_id = dl.empaque_id AND dp.calidad_id = dl.calidad_id
LEFT JOIN gold.dim_geografia dg ON dp.area_id_resuelta = dg.area_id
LEFT JOIN gold.dim_formato df ON dp.formato_id_resuelto = df.formato_id
LEFT JOIN gold.dim_idioma di ON dp.idioma_id_resuelto = di.idioma_id
GROUP BY 1, 2, 3, 4, 5, 6;
```

CAPÍTULO 9 & 10

Vistas Materializadas en Español y Medidas DAX Aditivas

Optimización OLAP en PostgreSQL 16 y consumo analítico en Power BI

9.1. Las 4 Vistas Materializadas Analíticas (sql/gold/05_aggregations.sql)

Vista Materializada en Español	Requerimientos	Atributos y Métricas Pre-Calculadas (SUM)
gold.mv_tendencias_produccion_anual	RF01 & RF05	anio, decada, siglo, lanzamientos_total, soportes_total, pistas_total, artistas_activos, duracion_promedio_segundos, cobertura_isrc_pct.
gold.mv_analitica_artistas	RF01, RF06 & RF08	artista_key, nombre_artista, tipo_artista, nombre_pais, anio_inicio, lanzamientos_total, pistas_total, pistas_con_isrc_total, cobertura_isrc_pct.
gold.mv_evolucion_formatos	RF02 & RF04	anio, decada, nombre_formato, categoria_formato, lanzamientos_total, soportes_total, pistas_total, pistas_largas_total, duracion_promedio_segundos.
gold.mv_distribucion_geografica	RF03 & RF06	geografia_key, nombre_pais, nombre_area, tipo_area, artistas_total, lanzamientos_total, pistas_total, pistas_con_isrc_total, duracion_total_horas.

10.1. Catálogo de Medidas DAX 100% Aditivas en Power BI

```
-- 1. VOLUMETRÍA HISTÓRICA ADITIVA
Total Lanzamientos = SUM(gold_fact_produccion_musical[lanzamientos_total])
Total Soportes     = SUM(gold_fact_produccion_musical[soportes_total])
Total Pistas       = SUM(gold_fact_produccion_musical[pistas_total])

-- 2. DURACIÓN PROMEDIO PONDERADA (SIN DISTORSIÓN POR CEROS)
Duracion Promedio por Pista (Segundos) =
DIVIDE(
    SUM(gold_fact_produccion_musical[duracion_total_segundos]),
    SUM(gold_fact_produccion_musical[pistas_completas_total]),
    0
)

-- 3. TASA DE FORMALIZACIÓN ISRC Y CANCIONES LARGAS (> 5 MIN)
Total Pistas con ISRC = SUM(gold_fact_produccion_musical[pistas_con_isrc_total])
Tasa Cobertura ISRC % = DIVIDE([Total Pistas con ISRC], [Total Pistas], 0)
Total Pistas Largas   = SUM(gold_fact_produccion_musical[pistas_largas_total])
Proporcion Largas %   = DIVIDE([Total Pistas Largas], [Total Pistas], 0)
```

CAPÍTULO 12 & 13

Defensa del Modelo Estrella y Lista de Verificación

Respuestas clave sobre el rediseño de la tabla de hechos y checklist de ejecución

P1: ¿Por qué la tabla de hechos ahora se llama gold.fact_produccion_musical y no contiene textos ni booleanos?

Respuesta de Defensa: Porque siguiendo estrictamente la teoría dimensional de Ralph Kimball y la corrección de la cátedra, una tabla de hechos debe almacenar el registro histórico cuantitativo del proceso de negocio en un grano definido (diario por dimensiones), conteniendo únicamente las claves foráneas (fecha_key, artista_key, lanzamiento_key, geografia_key, formato_key, idioma_key) y métricas numéricas 100% aditivas (lanzamientos_total, soportes_total, pistas_total, pistas_con_isrc_total, etc.).

P2: ¿Cómo lograron que lanzamientos_total sume múltiples lanzamientos por día en lugar de valer siempre 1?

Respuesta de Defensa: Transformamos gold.dim_lanzamiento en una Dimensión de Perfil de Lanzamiento conformada por las combinaciones únicas de estado_lanzamiento (Oficial, Promocional, Bootleg), tipo_empaque (Jewel Case, Digipak, Gatefold, Digital) y calidad_datos. Así evitamos una dimensión gigante de 5.8 millones de filas y logramos que todos los álbumes publicados por un artista en una fecha y formato se consoliden sumando el número real de lanzamientos en lanzamientos_total.

P3: ¿De dónde provienen las fechas históricas reales de publicación hacia gold.dim_fecha?

Respuesta de Defensa: Provienen directamente de las tablas oficiales silver.release_country y silver.release_unknown_country extraídas del dump mbdump.tar.bz2 (Schema Sequence 31), las cuales contienen las columnas date_year, date_month y date_day reales de cada evento de lanzamiento musical.

Secuencia Oficial de Comandos para Recrear y Certificar el DWH

```
# 1. Levantar contenedor PostgreSQL 16 (puerto 5435)
docker compose up -d

# 2. Crear esquemas (meta, silver, gold), 10 tablas Silver y Modelo Estrella en Español
python scripts/setup_database.py

# 3. Ingestar las 10 tablas Silver (extrae automáticamente desde mbdump.tar.bz2 si falta alguna)
python etl/silver/ingest_silver.py
python etl/silver/ingest_tracks_sliced.py

# 4. Poblar las 6 dimensiones en español, la tabla de hechos histórica y las 4 vistas materializadas
python etl/gold/run_gold_pipeline.py

# 5. Ejecutar auditoría de volumetría, métricas aditivas y cero huérfanos
python scripts/verify_dwh.py
```